Curso Libre de Configuración 2: Análisis de Datos
Tarea 3 – Introducción a Series de Tiempo

Daniela Natareno – dnatareno@unis.edu.gt

Fecha de entrega: 25 de octubre de 2026

Parte 0: Procesos simulados

Demostraciones matemáticas

Se considera un proceso autorregresivo de orden uno, AR(1), definido mediante la siguiente expresión:

$$Y_t = c + \phi Y_{t-1} + \varepsilon_t,$$

donde c es una constante, ϕ es el coeficiente autorregresivo y ε_t representa un término de ruido blanco, con media cero y varianza σ^2.

Se supone que el proceso es estacionario, que $|\phi| < 1$ y que ε_t es independiente de los valores pasados del proceso.

Bajo estas condiciones, se demostrarán las expresiones correspondientes a la esperanza, la varianza y la autocorrelación del modelo AR(1). Posteriormente, se analizará el caso particular de una caminata aleatoria.

a) Esperanza del proceso AR(1)

Se desea demostrar que:

$$E[Y_t] = \frac{c}{1-\phi}.$$

Partiendo de la definición del modelo:

$$Y_t = c + \phi Y_{t-1} + \varepsilon_t,$$

y se aplica el operador esperanza a ambos lados:

$$E[Y_t] = E[c + \phi Y_{t-1} + \varepsilon_t].$$

Por la propiedad de linealidad de la esperanza:

$$E[Y_t] = c + \phi E[Y_{t-1}] + E[\varepsilon_t].$$

Dado que el ruido blanco tiene media cero, $E[\varepsilon_t] = 0$, se obtiene:

$$E[Y_t] = c + \phi E[Y_{t-1}].$$

Como el proceso es estacionario, su esperanza permanece constante en el tiempo. Por lo tanto:

$$E[Y_t] = E[Y_{t-1}] = \mu.$$

Sustituyendo en la expresión anterior:

$$\begin{aligned} \mu &= c + \phi\mu, \\ \mu - \phi\mu &= c, \\ \mu(1-\phi) &= c. \end{aligned}$$

Finalmente, despejando μ:

$$\boxed{E[Y_t] = \frac{c}{1-\phi}}.$$

De esta manera, se demuestra que la esperanza del proceso AR(1) estacionario es constante y depende de la constante c y del coeficiente ϕ.

b) Varianza del proceso AR(1)

Se desea demostrar que:

$$\mathrm{Var}(Y_t) = \frac{\sigma^2}{1-\phi^2}.$$

Partiendo nuevamente del modelo AR(1):

$$Y_t = c + \phi Y_{t-1} + \varepsilon_t,$$

se aplica la varianza a ambos lados:

$$\mathrm{Var}(Y_t) = \mathrm{Var}(c + \phi Y_{t-1} + \varepsilon_t).$$

La varianza de una constante es cero. Además, debido a que ε_t es independiente del pasado, la covarianza entre Y_{t-1} y ε_t es cero.

Por lo tanto:

$$\mathrm{Var}(Y_t) = \phi^2 \,\mathrm{Var}(Y_{t-1}) + \mathrm{Var}(\varepsilon_t).$$

Como $\mathrm{Var}(\varepsilon_t) = \sigma^2$:

$$\mathrm{Var}(Y_t) = \phi^2 \,\mathrm{Var}(Y_{t-1}) + \sigma^2.$$

Por estacionariedad, la varianza permanece constante a lo largo del tiempo:

$$\mathrm{Var}(Y_t) = \mathrm{Var}(Y_{t-1}) = v.$$

Sustituyendo:

$$\begin{aligned} v &= \phi^2 v + \sigma^2, \\ v - \phi^2 v &= \sigma^2, \\ v(1-\phi^2) &= \sigma^2. \end{aligned}$$

Finalmente:

$$\boxed{\mathrm{Var}(Y_t) = \frac{\sigma^2}{1-\phi^2}}.$$

Se demuestra que la varianza del proceso AR(1) estacionario es constante. Además, cuando $|\phi|$ se aproxima a uno, la varianza aumenta, debido a que el denominador $1-\phi^2$ disminuye.

c) Autocorrelación del proceso AR(1)

Se desea demostrar que la autocorrelación en el rezago k está dada por:

$$\rho_k = \phi^k.$$

La autocovarianza del proceso para un rezago k se define como:

$$\gamma_k = \mathrm{Cov}(Y_t, Y_{t-k}).$$

Sustituyendo la expresión del modelo AR(1):

$$\gamma_k = \mathrm{Cov}(c + \phi Y_{t-1} + \varepsilon_t, Y_{t-k}).$$

Aplicando las propiedades de la covarianza:

$$\begin{aligned} \gamma_k = \phi\,&\mathrm{Cov}(Y_{t-1}, Y_{t-k}) \\ &+ \mathrm{Cov}(\varepsilon_t, Y_{t-k}). \end{aligned}$$

Para $k \geq 1$, el término ε_t es independiente de los valores anteriores del proceso. Por consiguiente:

$$\mathrm{Cov}(\varepsilon_t, Y_{t-k}) = 0.$$

Por estacionariedad, la covarianza depende únicamente de la separación temporal entre las observaciones. Así:

$$\gamma_k = \phi\gamma_{k-1}.$$

Aplicando esta relación de manera recursiva:

$$\begin{aligned} \gamma_1 &= \phi\gamma_0, \\ \gamma_2 &= \phi\gamma_1 = \phi^2\gamma_0, \\ \gamma_3 &= \phi\gamma_2 = \phi^3\gamma_0. \end{aligned}$$

Generalizando para cualquier rezago entero $k \geq 0$:

$$\gamma_k = \phi^k \gamma_0.$$

Por definición, la autocorrelación es la autocovarianza normalizada por la varianza del proceso:

$$\rho_k = \frac{\gamma_k}{\gamma_0}.$$

Sustituyendo la expresión obtenida:

$$\begin{aligned} \rho_k &= \frac{\phi^k \gamma_0}{\gamma_0} \\ &= \phi^k. \end{aligned}$$

Por lo tanto, suponiendo $\gamma_0 > 0$:

$$\boxed{\rho_k = \phi^k}.$$

Este resultado indica que, para $|\phi| < 1$, la magnitud de la autocorrelación disminuye geométricamente conforme aumenta el rezago.

Si ϕ es positivo, las autocorrelaciones son positivas; si es negativo, alternan de signo entre rezagos consecutivos.

d) Varianza de una caminata aleatoria

Se considera ahora el caso particular del modelo AR(1) con:

$$\phi = 1, \qquad c = 0, \qquad Y_0 = 0.$$

Bajo estas condiciones, el proceso se convierte en una caminata aleatoria:

$$Y_t = Y_{t-1} + \varepsilon_t.$$

Se desea demostrar que:

$$\mathrm{Var}(Y_t) = t\sigma^2.$$

Para ello, se desarrolla recursivamente la expresión del proceso.
Para $t = 1$:

$$\begin{aligned} Y_1 &= Y_0 + \varepsilon_1 \\ &= \varepsilon_1. \end{aligned}$$

Para $t = 2$:

$$\begin{aligned} Y_2 &= Y_1 + \varepsilon_2 \\ &= \varepsilon_1 + \varepsilon_2. \end{aligned}$$

Para $t = 3$:

$$\begin{aligned} Y_3 &= Y_2 + \varepsilon_3 \\ &= \varepsilon_1 + \varepsilon_2 + \varepsilon_3. \end{aligned}$$

Siguiendo este patrón, para un tiempo arbitrario t se obtiene:

$$Y_t = \sum_{i=1}^{t} \varepsilon_i.$$

Aplicando el operador varianza:

$$\mathrm{Var}(Y_t) = \mathrm{Var}\left(\sum_{i=1}^{t} \varepsilon_i \right).$$

Debido a que los términos de ruido blanco son independientes, la varianza de su suma es igual a la suma de sus varianzas:

$$\mathrm{Var}(Y_t) = \sum_{i=1}^{t} \mathrm{Var}(\varepsilon_i).$$

Como cada término tiene varianza σ^2:

$$\begin{aligned} \mathrm{Var}(Y_t) &= \sum_{i=1}^{t} \sigma^2 \\ &= \underbrace{\sigma^2 + \sigma^2 + \cdots + \sigma^2}_{t \text{ términos}}. \end{aligned}$$

Por lo tanto:

$$\boxed{\mathrm{Var}(Y_t) = t\sigma^2}.$$

¿Por qué la caminata aleatoria no es estacionaria? Para que un proceso sea estacionario en sentido débil, su media y varianza deben permanecer constantes en el tiempo, y su autocovarianza debe depender únicamente del rezago entre observaciones.

En el caso de la caminata aleatoria, se ha demostrado que:

$$\mathrm{Var}(Y_t) = t\sigma^2.$$

Esta expresión depende directamente del tiempo t. Por lo tanto, cuando $\sigma^2 > 0$, la varianza aumenta conforme transcurren los períodos.

Aunque la esperanza del proceso es constante e igual a cero, su varianza no cumple la condición de estacionariedad.

En consecuencia:

$$\boxed{\text{La caminata aleatoria no es estacionaria.}}$$

Conclusión Se demostraron las expresiones de esperanza, varianza y autocorrelación de un proceso AR(1) estacionario. Estas propiedades permiten caracterizar su comportamiento temporal y muestran que, cuando $|\phi| < 1$, la influencia de las observaciones pasadas disminuye con el rezago.

En contraste, al considerar $\phi = 1$, el modelo se convierte en una caminata aleatoria cuya varianza crece linealmente con el tiempo. Esto impide que el proceso sea estacionario y evidencia la diferencia entre ambos modelos.

Simulación de procesos AR(1)

Se simularon procesos autorregresivos de orden uno, AR(1), con el propósito de observar cómo cambia su comportamiento cuando se modifica el coeficiente autorregresivo ϕ. Se utilizó el siguiente modelo:

$$Y_t = \phi Y_{t-1} + \varepsilon_t, \qquad \varepsilon_t \sim N(0,1).$$

Para las simulaciones se estableció $c = 0$, $\sigma = 1$ y se consideraron los valores $\phi \in \{0, 0{,}5, 0{,}9, 1\}$. En cada realización se generaron 500 observaciones, de las cuales se descartaron las primeras 200, conservando una serie de longitud $n = 300$.

Posteriormente, se realizaron 5000 réplicas independientes para cada valor de ϕ, utilizando semillas diferentes para cada escenario. A partir de estas réplicas se calcularon los promedios de las autocorrelaciones muestrales r_1 y r_5, la proporción de rechazos de una prueba de ruido blanco y el promedio de las estimaciones del coeficiente autorregresivo mediante mínimos cuadrados ordinarios (OLS).

a) Realizaciones de los procesos simulados

La Figura 1 presenta una realización de cada uno de los cuatro procesos simulados.

Cuando $\phi = 0$, la serie corresponde a ruido blanco y presenta fluctuaciones alrededor de cero sin dependencia temporal sistemática. Para $\phi = 0{,}5$, las observaciones consecutivas muestran una persistencia moderada. Cuando $\phi = 0{,}9$, la dependencia temporal es más fuerte y las variaciones tienden a mantenerse durante períodos prolongados.

En el caso de $\phi = 1$, el proceso corresponde a una caminata aleatoria. En la realización obtenida, la serie permanece por encima de cero y muestra cambios persistentes en su nivel. Este comportamiento es consistente con un proceso no estacionario, cuya varianza aumenta con el tiempo.

b) Autocorrelaciones muestrales

Para cada réplica se calcularon las autocorrelaciones muestrales correspondientes a los rezagos uno y cinco. Se utilizó la siguiente expresión:

$$r_k = \frac{\sum_{t=k+1}^{n}(Y_t - \bar{Y})(Y_{t-k} - \bar{Y})}{\sum_{t=1}^{n}(Y_t - \bar{Y})^2},$$

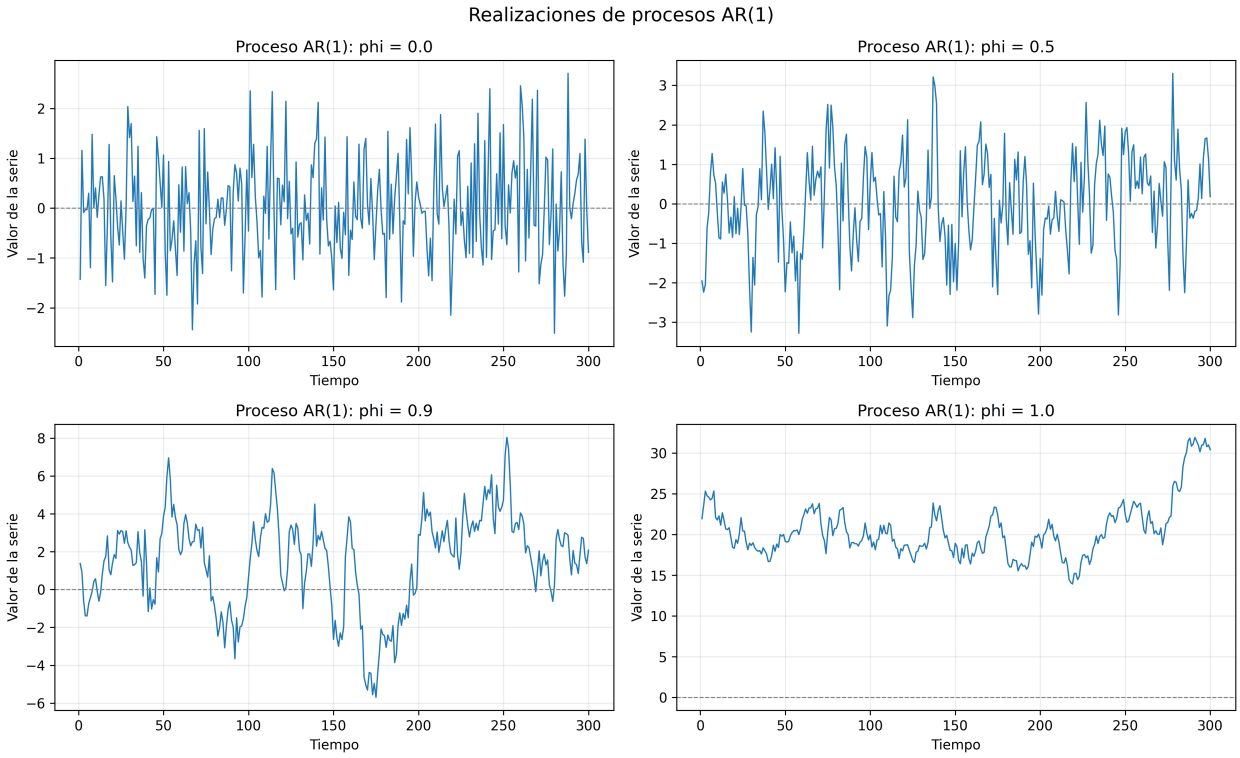


Figura 1: Realizaciones de 300 observaciones de procesos AR(1) para distintos valores de ϕ, después de descartar las primeras 200 observaciones.

donde k representa el rezago, $n = 300$ es el número de observaciones y $\bar{Y}$ es la media muestral de la serie.

En primer inciso se demostró que, para un proceso AR(1) estacionario, la autocorrelación teórica es $\rho_k = \phi^k$. Por lo tanto, para el quinto rezago se utiliza ϕ^5 como valor de referencia.

Cuadro 1: Promedios de autocorrelaciones muestrales en 5000 réplicas.

ϕ	Promedio r_1	Promedio r_5	ϕ^5
0.0	-0.00374	-0.00158	0.00000
0.5	0.48901	0.02091	0.03125
0.9	0.88415	0.53337	0.59049
1.0	0.97562	0.88264	1.00000

Los resultados muestran que la autocorrelación muestral aumenta conforme el valor de ϕ se aproxima a uno. Para $\phi = 0$, ambos promedios son cercanos a cero, como se espera de un proceso de ruido blanco. Para $\phi = 0{,}5$ y $\phi = 0{,}9$, los promedios reflejan una dependencia temporal positiva, aunque los valores estimados se encuentran ligeramente por debajo de sus referencias teóricas.

Para $\phi = 1$, el valor $\phi^5 = 1$ se presenta únicamente como referencia numérica solicitada en el ejercicio. Debido a que la caminata aleatoria no es estacionaria, no corresponde interpretarlo como una autocorrelación teórica estacionaria.

c) Prueba de ruido blanco

Para evaluar la presencia de autocorrelación en el primer rezago, se utilizó el criterio de rechazo:

$$|r_1| > \frac{1{,}96}{\sqrt{n}}.$$

Sustituyendo $n = 300$:

$$\frac{1{,}96}{\sqrt{300}} \approx 0{,}11316.$$

En cada réplica se registró si el valor absoluto de r_1 superaba este umbral. La tasa de rechazo se calculó como la proporción de réplicas que cumplieron dicha condición.

Cuadro 2: Tasa de rechazo de la prueba de ruido blanco y estimación OLS.

ϕ	Tasa de rechazo	Promedio $\hat{\phi}_{OLS}$
0.0	5.04 %	-0.00375
0.5	100.00 %	0.49068
0.9	100.00 %	0.88721
1.0	100.00 %	0.98221

Para $\phi = 0$, la tasa de rechazo fue de 5.04 %, un resultado cercano al nivel de significancia del 5 %. Para $\phi = 0{,}5$, $\phi = 0{,}9$ y $\phi = 1$, el criterio rechazó la hipótesis de ruido blanco en el 100 % de las réplicas, lo cual refleja la fuerte evidencia de dependencia temporal en estos escenarios.

d) Estimación del coeficiente autorregresivo mediante OLS

En cada réplica se estimó el coeficiente ϕ mediante una regresión lineal de Y_t sobre Y_{t-1}, incluyendo un intercepto. La estimación del coeficiente se obtuvo mediante:

$$\hat{\phi}_{OLS} = \frac{\sum_{t=2}^{n}(Y_{t-1} - \bar{Y}_{-1})(Y_t - \bar{Y}_{+1})}{\sum_{t=2}^{n}(Y_{t-1} - \bar{Y}_{-1})^2},$$

donde $\bar{Y}_{-1}$ representa la media de las observaciones utilizadas como variable explicativa y $\bar{Y}_{+1}$ corresponde a la media de las observaciones utilizadas como variable dependiente.

Los promedios de las estimaciones OLS, presentados en la Tabla 2, se aproximan a los valores utilizados para generar cada proceso. Sin embargo, en los escenarios con mayor persistencia, especialmente cuando $\phi = 1$, se observa una estimación promedio inferior al valor verdadero.

e) Errores estándar de los promedios

Para medir la precisión de los resultados obtenidos en las 5000 réplicas, se calculó el error estándar de cada promedio mediante la expresión:

$$EE(\bar{x}) = \frac{s}{\sqrt{R}},$$

donde s es la desviación estándar muestral del estadístico entre las réplicas y $R = 5000$ es la cantidad de simulaciones realizadas.

En el caso de la tasa de rechazo, cada réplica se representó mediante una variable indicadora que toma el valor uno cuando se rechaza la hipótesis de ruido blanco y cero en caso contrario. Su error estándar se calculó utilizando el mismo procedimiento.

Cuadro 3: Errores estándar de los estadísticos calculados en 5000 réplicas.

ϕ	$EE(\overline{r_1})$	$EE(\overline{r_5})$	$EE(\text{tasa de rechazo})$	$EE(\overline{\hat{\phi}}_{OLS})$
0.0	0.000819	0.000802	0.003094	0.000822
0.5	0.000706	0.001038	0.000000	0.000708
0.9	0.000396	0.001392	0.000000	0.000394
1.0	0.000206	0.000923	0.000000	0.000212

Los errores estándar de los promedios son pequeños, lo que indica que los resultados presentan una precisión elevada respecto a la variabilidad entre réplicas. En los escenarios donde todas las réplicas rechazaron la hipótesis de ruido blanco, el error estándar empírico de la tasa de rechazo fue cero, debido a que no se observó variación en las decisiones de rechazo.

f) Efecto del descarte de las primeras 200 observaciones

En los procesos AR(1) estacionarios, la influencia del valor inicial disminuye con el tiempo debido a que $|\phi| < 1$. En particular, la contribución del valor inicial después de t períodos es proporcional a ϕ^t, por lo que descartar las primeras 200 observaciones reduce su influencia sobre la serie analizada.

Sin embargo, cuando $\phi = 1$, el proceso corresponde a una caminata aleatoria:

$$Y_t = Y_0 + \sum_{i=1}^{t} \varepsilon_i.$$

En este caso, el efecto del nivel inicial no disminuye con el tiempo. Por ello, descartar las primeras 200 observaciones no hace que el proceso alcance una distribución estacionaria.

No obstante, la autocorrelación muestral r_k es invariante ante la suma de una constante a todas las observaciones. Si se define $Z_t = Y_t + a$, entonces su media es $\bar{Z} = \bar{Y} + a$, por lo que:

$$Z_t - \bar{Z} = (Y_t + a) - (\bar{Y} + a) = Y_t - \bar{Y}.$$

Por lo tanto, las desviaciones respecto a la media no cambian y el valor de r_k permanece igual. Esto explica por qué el nivel acumulado antes del período observado no afecta la autocorrelación muestral de la caminata aleatoria.

Conclusión del ejercicio 0.2 Las simulaciones permitieron observar que el aumento de ϕ produce una mayor persistencia temporal en las series. Los promedios de autocorrelación y las estimaciones OLS reflejan este comportamiento, mientras que la prueba de ruido blanco distingue claramente el escenario sin autocorrelación de aquellos con dependencia temporal. Finalmente, la caminata aleatoria presenta un comportamiento diferente al de los procesos estacionarios, ya que su nivel depende de la acumulación de perturbaciones y su varianza aumenta con el tiempo.

Interpretación de los resultados de simulación

A partir de las 5000 réplicas realizadas en el inciso anterior, se analizan la tasa de rechazo de la prueba de ruido blanco, la autocorrelación muestral de la caminata aleatoria y el comportamiento de las estimaciones del coeficiente autorregresivo mediante mínimos cuadrados ordinarios (OLS).

a) Tasa de rechazo para $\phi = 0$

Cuando $\phi = 0$, el modelo AR(1) se reduce a $Y_t = \varepsilon_t$, por lo que las observaciones corresponden a un proceso de ruido blanco sin autocorrelación teórica.

La prueba utilizada rechaza la hipótesis de ruido blanco cuando se cumple:

$$|r_1| > \frac{1{,}96}{\sqrt{300}} \approx 0{,}11316.$$

Este criterio corresponde a una prueba bilateral con un nivel de significancia aproximado del 5 %. Por lo tanto, cuando la hipótesis nula es verdadera, se espera que aproximadamente el 5 % de las réplicas produzcan un rechazo debido a la variabilidad muestral.

En la simulación se obtuvo una tasa de rechazo de 5.04 %, muy cercana al valor esperado de 5 %. La diferencia de 0.04 puntos porcentuales es pequeña y resulta compatible con la variación aleatoria de las 5000 réplicas.

Por lo tanto, la tasa de rechazo observada es coherente con el comportamiento esperado de la prueba cuando el proceso realmente es ruido blanco.

b) Autocorrelación de la caminata aleatoria

Para la caminata aleatoria, correspondiente a $\phi = 1$, el promedio de la autocorrelación muestral en el quinto rezago fue:

$$\overline{r_5} = 0{,}88264.$$

Al compararlo con el valor de referencia $\phi^5 = 1$, se obtiene:

$$0{,}88264 - 1 = -0{,}11736.$$

Aunque la autocorrelación estimada es elevada, se encuentra por debajo de uno. Esta diferencia debe interpretarse considerando que la expresión teórica $\rho_k = \phi^k$ se demostró bajo el supuesto de estacionariedad, el cual requiere $|\phi| < 1$.

Cuando $\phi = 1$, el proceso es una caminata aleatoria y su varianza aumenta con el tiempo, por lo que no cumple las condiciones necesarias para utilizar la expresión de autocorrelación estacionaria.

Además, la autocorrelación muestral se calcula sobre una serie de longitud finita y utilizando desviaciones respecto a su media muestral. Por ello, el promedio obtenido no necesariamente coincide con el valor de referencia uno.

En consecuencia, el resultado muestra una dependencia temporal elevada, pero no debe interpretarse como una estimación de una autocorrelación teórica estacionaria igual a uno.

c) Sesgo de las estimaciones OLS

Para evaluar el comportamiento de las estimaciones OLS, se comparó el promedio del coeficiente estimado con el valor verdadero de ϕ utilizado en cada simulación.

El sesgo observado se calculó mediante:

$$\text{Sesgo observado} = \overline{\hat{\phi}}_{OLS} - \phi.$$

Los resultados se presentan en la Tabla 4.

Cuadro 4: Sesgo observado de las estimaciones OLS para cada valor de ϕ.

ϕ verdadero	Promedio $\hat{\phi}_{OLS}$	Sesgo observado
0.0	-0.00375	-0.00375
0.5	0.49068	-0.00932
0.9	0.88721	-0.01279
1.0	0.98221	-0.01779

En los cuatro escenarios se observa que el promedio de las estimaciones OLS es inferior al valor verdadero de ϕ, lo que indica un sesgo negativo en las simulaciones realizadas.

Para $\phi = 0$, el sesgo es pequeño y la estimación promedio se encuentra muy cerca de cero. Conforme aumenta el coeficiente autorregresivo, la magnitud del sesgo negativo también aumenta. El mayor sesgo observado corresponde a la caminata aleatoria, con $\phi = 1$, cuyo promedio estimado fue 0.98221.

Este comportamiento indica que, para muestras de longitud $n = 300$, el procedimiento OLS tiende a subestimar el coeficiente autorregresivo, especialmente cuando el proceso presenta una persistencia elevada.

Es importante distinguir entre sesgo y consistencia. El sesgo observado corresponde a una muestra de tamaño finito, mientras que la consistencia se refiere al comportamiento de un estimador cuando el tamaño de la muestra tiende a infinito. Por lo tanto, estos resultados permiten identificar un sesgo de muestra finita, pero no son suficientes por sí solos para evaluar la consistencia asintótica del estimador.

Conclusión Los resultados muestran que la prueba de ruido blanco presenta una tasa de rechazo cercana al 5 % esperado cuando $\phi = 0$. Para la caminata aleatoria, la autocorrelación muestral del quinto rezago es elevada, aunque inferior al valor de referencia uno, debido a que el proceso no cumple el supuesto de estacionariedad utilizado en la expresión teórica. Finalmente, las estimaciones OLS presentan un sesgo negativo que aumenta en magnitud conforme ϕ se aproxima a uno, lo cual evidencia la importancia de considerar los efectos del tamaño de muestra al estimar procesos autorregresivos.

Las dos razones para reprobar

En este ejercicio se analizaron dos procesos sin memoria, pero con medias que cambian a lo largo del tiempo. El objetivo fue comprobar que una serie puede presentar autocorrelación muestral debido a cambios en su media, incluso cuando las perturbaciones son independientes.

Los procesos simulados se definieron mediante:

$$Y_t = m_t + \varepsilon_t, \qquad \varepsilon_t \overset{iid}{\sim} N(0,1),$$

donde m_t representa una media determinista que depende del tiempo y ε_t corresponde a perturbaciones independientes con media cero y varianza uno.

Se consideraron dos escenarios: una tendencia lineal creciente y un patrón semanal. Para cada escenario se generaron series de 300 observaciones y se realizaron 5000 réplicas independientes, utilizando semillas diferentes.

a) Procesos simulados

Tendencia lineal El primer proceso utiliza una media que aumenta progresivamente a lo largo de los 300 períodos:

$$m_t = \frac{2t}{300}, \qquad t = 1, \ldots, 300.$$

Esta expresión produce una tendencia creciente que comienza cerca de cero y alcanza el valor dos en la última observación. Aunque las perturbaciones son independientes, las observaciones tienden a presentar valores mayores conforme avanza el tiempo.

Patrón semanal El segundo proceso utiliza una media que se repite cada siete observaciones:

$$m_t = \begin{cases} -1{,}5, & \text{si } t \text{ mód } 7 = 6, \\ 0{,}25, & \text{en los demás casos.} \end{cases}$$

En este escenario, la media toma normalmente el valor 0.25, pero disminuye a $-1{,}5$ cada siete períodos. Esto introduce una estructura periódica sin establecer una dependencia directa entre las perturbaciones de diferentes momentos.

La Figura 2 muestra una realización de cada proceso junto con su media determinista.

En el proceso con tendencia lineal se observa un incremento gradual del nivel de la serie, acompañado de fluctuaciones aleatorias. En el proceso semanal, la media presenta disminuciones periódicas que se repiten cada siete observaciones, aunque estas pueden quedar parcialmente ocultas por el ruido aleatorio.

b) Autocorrelaciones muestrales

Para cada una de las 5000 réplicas se calcularon las autocorrelaciones muestrales en los rezagos uno, cinco y siete, utilizando la misma expresión anteriormente:

$$r_k = \frac{\sum_{t=k+1}^{n}(Y_t - \bar{Y})(Y_{t-k} - \bar{Y})}{\sum_{t=1}^{n}(Y_t - \bar{Y})^2}.$$

Se incluyó el rezago siete para identificar la posible estructura periódica del segundo proceso. Los resultados promedio se presentan en la Tabla 5.

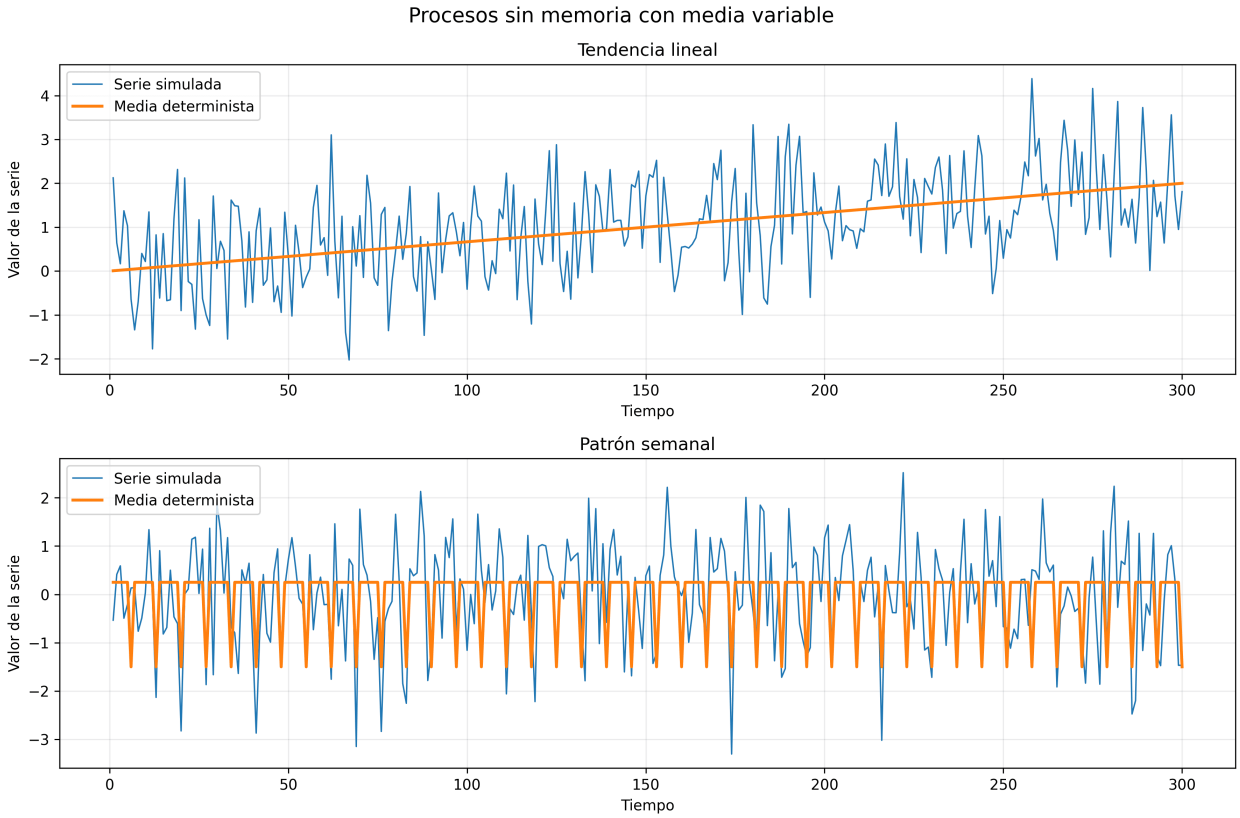


Figura 2: Realizaciones de procesos sin memoria con tendencia lineal y patrón semanal. La línea continua de referencia representa la media determinista de cada escenario.

Cuadro 5: Promedios de autocorrelaciones muestrales en 5000 réplicas.

Proceso	Promedio r_1	Promedio r_5	Promedio r_7
Tendencia lineal	0.245672	0.233998	0.229863
Patrón semanal	-0.047186	-0.047994	0.264204

En el proceso con tendencia lineal, las autocorrelaciones promedio son positivas en los tres rezagos. Esto ocurre porque las observaciones cercanas comparten niveles similares de la media determinista, lo que produce una asociación temporal aparente a pesar de que las perturbaciones son independientes.

En el patrón semanal, los promedios de r_1 y r_5 son ligeramente negativos y cercanos a cero en comparación con r_7. En cambio, el promedio de r_7 alcanza 0.264204, lo que evidencia la repetición de la estructura cada siete observaciones.

c) Prueba de ruido blanco en el primer rezago

Se aplicó el mismo criterio de rechazo utilizado anteriormente:

$$|r_1| > \frac{1{,}96}{\sqrt{n}}.$$

Para $n = 300$, el umbral corresponde a:

$$\frac{1{,}96}{\sqrt{300}} \approx 0{,}11316.$$

La tasa de rechazo se calculó como la proporción de las 5000 réplicas en las que el valor absoluto de r_1 superó dicho umbral.

Cuadro 6: Tasas de rechazo y estimaciones OLS de los procesos con media variable.

Proceso	Tasa de rechazo	Promedio $\hat{\phi}_{OLS}$
Tendencia lineal	98.48 %	0.246940
Patrón semanal	10.86 %	-0.047564

El proceso con tendencia lineal presentó una tasa de rechazo del 98.48 %, a pesar de que sus perturbaciones son independientes. Esto demuestra que la prueba puede detectar autocorrelación muestral producida por una media no constante, sin que exista memoria autorregresiva en el proceso.

Por otra parte, el patrón semanal presentó una tasa de rechazo del 10.86 %. Esto significa que en el 89.14 % de las réplicas la prueba del primer rezago no rechazó la hipótesis de ruido blanco, aunque la serie contenía una estructura periódica definida.

Por lo tanto, la tendencia lineal es el proceso que reprueba la prueba de primer rezago aunque no tenga memoria, mientras que el patrón semanal es el proceso que generalmente la pasa a pesar de presentar una estructura temporal.

d) Estimaciones OLS

Para mantener la comparación con el inciso anterior, se ajustó una regresión de Y_t contra Y_{t-1} con intercepto y se calculó el promedio del coeficiente estimado mediante OLS.

Como se observa en la Tabla 6, la tendencia lineal produjo un coeficiente promedio de 0.246940, mientras que el patrón semanal produjo un coeficiente promedio de $-0{,}047564$.

Estos coeficientes no deben interpretarse como parámetros autorregresivos verdaderos, debido a que los procesos simulados no incluyen el término ϕY_{t-1} en su definición. Las estimaciones reflejan la asociación entre observaciones consecutivas generada por la estructura de sus medias.

e) Errores estándar

Para cada estadístico se calculó el error estándar de su promedio utilizando las 5000 réplicas:

$$EE(\bar{x}) = \frac{s}{\sqrt{5000}},$$

donde s representa la desviación estándar muestral del estadístico entre réplicas independientes.

Cuadro 7: Errores estándar de los promedios y de la tasa de rechazo.

Proceso	$EE(\overline{r_1})$	$EE(\overline{r_5})$	$EE(\overline{r_7})$	$EE(\text{tasa})$	$EE(\overline{\hat{\phi}_{OLS}})$
Tendencia lineal	0.000844	0.000822	0.000825	0.001730	0.000849
Patrón semanal	0.000763	0.000756	0.000819	0.004401	0.000769

Los errores estándar obtenidos son pequeños, lo que indica que los promedios calculados presentan una variabilidad reducida entre las 5000 réplicas. Esto permite comparar con mayor precisión el comportamiento de ambos escenarios.

f) Relación con RANDU y las limitaciones de la prueba

Los resultados muestran que evaluar únicamente la autocorrelación del primer rezago no es suficiente para identificar todas las estructuras temporales presentes en una serie.

En el proceso con tendencia lineal, la prueba rechaza frecuentemente la hipótesis de ruido blanco porque la media cambia con el tiempo. Sin embargo, esto no significa que las perturbaciones tengan memoria, sino que la serie no mantiene una media constante.

En el patrón semanal ocurre lo contrario: la prueba del primer rezago generalmente no rechaza la hipótesis, aunque existe una estructura periódica que se manifiesta claramente en el séptimo rezago.

Este comportamiento se relaciona con el generador RANDU estudiado en la Tarea 2, ya que una secuencia puede parecer adecuada al evaluarse mediante una prueba particular y,

al mismo tiempo, presentar patrones que esa prueba no logra detectar. En ambos casos, el problema consiste en utilizar una evaluación parcial como si fuera suficiente para descartar cualquier estructura.

Por ello, resulta importante examinar diferentes rezagos y utilizar pruebas que consideren varias autocorrelaciones de manera conjunta, en lugar de depender exclusivamente de la autocorrelación del primer rezago.

Conclusión Las simulaciones demostraron que una media variable puede generar autocorrelación muestral aun cuando las perturbaciones sean independientes. La tendencia lineal produjo una tasa de rechazo del 98.48 %, mientras que el patrón semanal generalmente superó la prueba del primer rezago, pero presentó una autocorrelación elevada en el séptimo rezago. Estos resultados evidencian que la autocorrelación observada no siempre representa memoria del proceso y que una prueba limitada a un solo rezago puede pasar por alto estructuras periódicas importantes.

La prueba que sí ve

En los ejercicios anteriores se observó que la prueba de autocorrelación del primer rezago puede rechazar la hipótesis de ruido blanco cuando existe una tendencia determinista y, al mismo tiempo, puede no detectar una estructura periódica presente en la serie. Para evaluar estas limitaciones, se aplicó la prueba de Ljung–Box, que permite examinar conjuntamente las autocorrelaciones de varios rezagos.

Se consideraron tres procesos: ruido blanco, un proceso con tendencia lineal y un proceso con patrón semanal. Para cada escenario se realizaron 5000 réplicas independientes de 300 observaciones, utilizando un nivel de significancia del 5 % y los primeros diez rezagos.

a) Estadístico de Ljung–Box

La prueba de Ljung–Box permite evaluar la hipótesis nula de que las autocorrelaciones de los primeros m rezagos son iguales a cero. En este ejercicio se utilizaron las siguientes hipótesis:

$$H_0 : \rho_1 = \rho_2 = \cdots = \rho_{10} = 0,$$
$$H_1 : \text{Al menos una de estas autocorrelaciones es distinta de cero.}$$

El estadístico de prueba se calcula mediante:

$$Q(m) = n(n+2) \sum_{k=1}^{m} \frac{r_k^2}{n-k},$$

donde n es el número de observaciones, m es la cantidad de rezagos considerados y r_k representa la autocorrelación muestral correspondiente al rezago k.

Para $n = 300$ y $m = 10$, la expresión utilizada fue:

$$Q(10) = 300(302) \sum_{k=1}^{10} \frac{r_k^2}{300 - k}.$$

Bajo la hipótesis nula y para un tamaño de muestra suficientemente grande, el estadístico sigue aproximadamente una distribución chi-cuadrado con diez grados de libertad:

$$Q(10) \overset{\text{aprox.}}{\sim} \chi^2_{10}.$$

La decisión se tomó comparando el valor p obtenido con el nivel de significancia $\alpha = 0{,}05$. Se rechazó la hipótesis nula cuando $p < 0{,}05$.

b) Implementación y verificación

La prueba se implementó en Python calculando las autocorrelaciones muestrales de los diez primeros rezagos, sumando sus contribuciones al estadístico $Q(10)$ y obteniendo el valor p mediante la función de supervivencia de la distribución chi-cuadrado.

Para comprobar la implementación, se compararon los resultados del cálculo manual con los obtenidos mediante la función `acorr_ljungbox` de la biblioteca `statsmodels`, utilizando la misma serie simulada y diez rezagos. El programa verificó numéricamente la coincidencia de ambos procedimientos.

Posteriormente, se ejecutaron 5000 réplicas para cada proceso. En cada una se registró si la prueba del primer rezago rechazaba la hipótesis de ruido blanco y si la prueba de Ljung–Box producía un valor p inferior a 0.05. Las tasas de rechazo se calcularon como la proporción de réplicas en las que se produjo un rechazo.

c) Comparación de las tasas de rechazo

La Tabla 8 presenta las tasas de rechazo obtenidas mediante la prueba del primer rezago y la prueba de Ljung–Box con diez rezagos.

Cuadro 8: Comparación de las tasas de rechazo de ambas pruebas en 5000 réplicas.

Proceso	Prueba de rezago 1	Ljung–Box $Q(10)$
Ruido blanco	4.76 %	5.32 %
Tendencia lineal	98.38 %	100.00 %
Patrón semanal	10.72 %	95.76 %

En el proceso de ruido blanco, ambas pruebas presentaron tasas de rechazo cercanas al 5 % esperado. La prueba del primer rezago rechazó en el 4.76 % de las réplicas, mientras que Ljung–Box rechazó en el 5.32 %. Estos resultados son coherentes con el nivel de significancia utilizado.

Para el proceso con tendencia lineal, la prueba del primer rezago presentó una tasa de rechazo del 98.38 %, mientras que Ljung–Box rechazó en el 100 % de las réplicas. Esto ocurre porque la tendencia genera asociaciones entre observaciones de distintos períodos, aunque las perturbaciones del proceso sean independientes.

En el patrón semanal se observó la diferencia más importante. La prueba del primer rezago rechazó únicamente en el 10.72 % de las réplicas, mientras que Ljung–Box alcanzó una tasa de rechazo del 95.76 %. Este resultado muestra que considerar varios rezagos permite identificar una estructura periódica que generalmente no se detecta al examinar únicamente el primer rezago.

La Figura 3 presenta gráficamente las tasas de rechazo obtenidas.

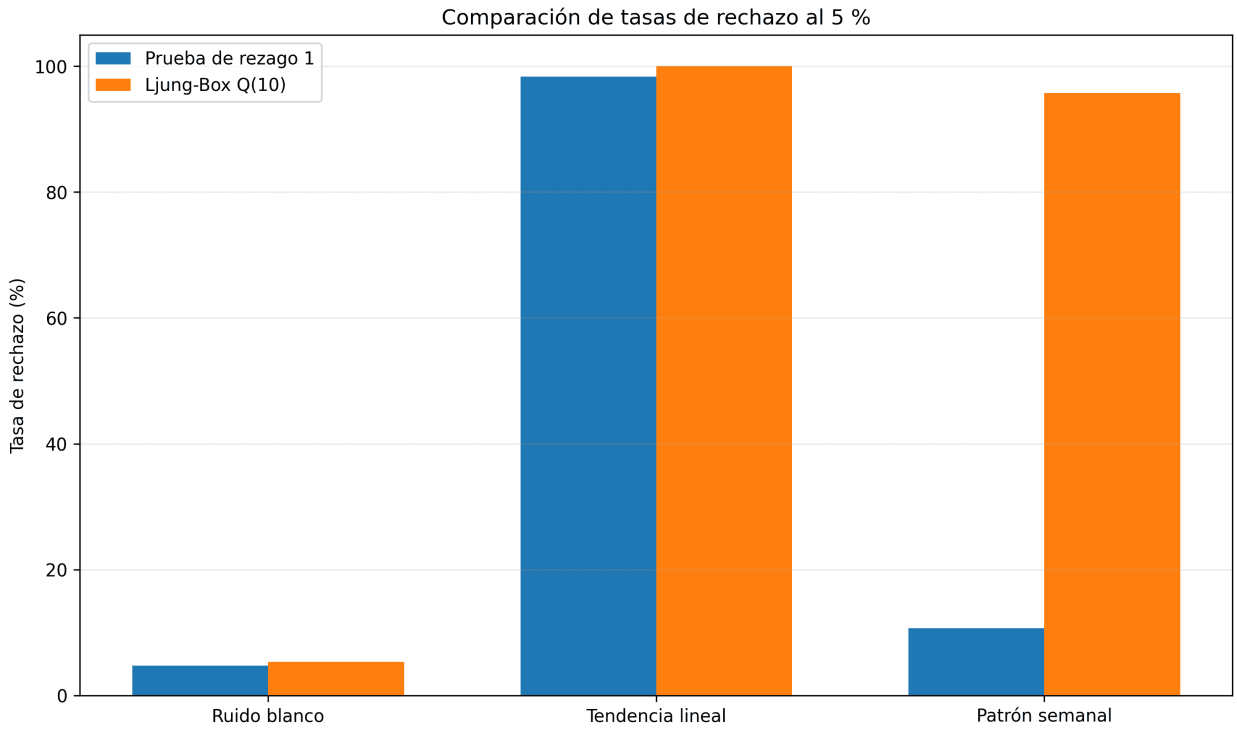


Figura 3: Comparación de las tasas de rechazo de la prueba del primer rezago y Ljung–Box con diez rezagos, utilizando un nivel de significancia del 5 %.

d) Estadísticos de Ljung–Box y errores estándar

Además de las tasas de rechazo, se calculó el promedio del estadístico $Q(10)$ y los errores estándar de los resultados obtenidos en las 5000 réplicas.

El error estándar de cada promedio se calculó mediante:

$$EE(\bar{x}) = \frac{s}{\sqrt{5000}},$$

donde s representa la desviación estándar muestral del estadístico entre las réplicas.

Cuadro 9: Estadísticos promedio y errores estándar de las pruebas.

Proceso	Promedio $Q(10)$	$EE(Q(10))$	EE(rechazo r_1)	EE(rechazo Ljung–Box)
Ruido blanco	10.018719	0.065654	0.003011	0.003174
Tendencia lineal	179.777220	0.840987	0.001786	0.000000
Patrón semanal	36.365893	0.168240	0.004376	0.002850

El promedio de $Q(10)$ para el ruido blanco fue aproximadamente 10.02, cercano al valor esperado de una distribución chi-cuadrado con diez grados de libertad. En cambio, la tendencia lineal y el patrón semanal produjeron estadísticos considerablemente mayores, lo que explica sus elevadas tasas de rechazo.

El error estándar empírico de la tasa de rechazo de Ljung–Box para la tendencia lineal fue cero porque todas las réplicas produjeron un rechazo. Este valor describe la ausencia de variación observada en las decisiones de las 5000 simulaciones.

e) ¿Qué cambia respecto a la prueba del primer rezago y por qué?

La diferencia principal entre ambas pruebas es la cantidad de autocorrelaciones consideradas. La prueba del primer rezago utiliza únicamente r_1, mientras que Ljung–Box acumula información de los primeros diez rezagos mediante la suma de sus autocorrelaciones al cuadrado.

En el patrón semanal, la estructura se repite cada siete períodos. Por lo tanto, la autocorrelación del séptimo rezago contiene información relevante sobre esta periodicidad, aunque la autocorrelación del primer rezago sea relativamente pequeña.

Al incluir el séptimo rezago dentro del estadístico $Q(10)$, Ljung–Box logra detectar el patrón semanal con mucha mayor frecuencia. En las simulaciones realizadas, la tasa de rechazo aumentó del 10.72 % al 95.76 %, una diferencia de 85.04 puntos porcentuales.

Para el ruido blanco, ambas pruebas mantienen tasas de rechazo cercanas al nivel de significancia establecido, debido a que no existe una estructura temporal sistemática que deba detectarse.

En la tendencia lineal, ambas pruebas rechazan con mucha frecuencia porque la media del proceso cambia con el tiempo. Sin embargo, este resultado no implica que las perturbaciones presenten dependencia autorregresiva. La prueba identifica autocorrelación en la serie observada, pero no determina por sí sola cuál es su causa.

En consecuencia, Ljung–Box permite detectar estructuras que pueden pasar inadvertidas al revisar un único rezago, aunque sus resultados siempre deben interpretarse considerando las características del proceso analizado.

Conclusión La prueba de Ljung–Box permitió identificar con mayor eficacia la estructura periódica del proceso semanal, aumentando su tasa de rechazo del 10.72 % al 95.76 %. Para el ruido blanco, ambas pruebas mantuvieron tasas cercanas al 5 %, mientras que la tendencia lineal produjo rechazos frecuentes debido a su media no constante. Estos resultados

demuestran la importancia de evaluar conjuntamente varios rezagos y de distinguir entre la autocorrelación generada por una estructura determinista y la dependencia temporal de las perturbaciones.

Parte 1: Limpieza de datos

Carga y exploración inicial de los datos

Para el análisis se utilizó el conjunto de datos *Online Retail*, correspondiente a las transacciones de una tienda en línea del Reino Unido entre el 1 de diciembre de 2010 y el 9 de diciembre de 2011. El archivo original se encuentra en formato Excel y contiene información sobre facturas, productos, cantidades, precios, clientes y países.

Los datos se cargaron utilizando la biblioteca `pandas` de Python. Durante la lectura se especificó que las columnas `InvoiceNo`, `StockCode` y `CustomerID` fueran tratadas como texto, debido a que representan identificadores y no cantidades numéricas. Asimismo, se verificó que la columna `InvoiceDate` estuviera representada mediante un tipo de dato de fecha y hora.

Antes de aplicar cualquier procedimiento de limpieza, se calcularon la cantidad total de filas, el número de facturas diferentes, los productos distintos, los clientes identificados y la proporción de registros sin identificador de cliente.

Los resultados obtenidos se presentan en la Tabla 10.

Cuadro 10: Resultados de la exploración inicial del conjunto de datos Online Retail.

Indicador	Resultado
Total de filas	541,909
Facturas diferentes	25,900
Productos diferentes	4,070
Clientes diferentes	4,372
Filas sin `CustomerID`	135,080
Porcentaje de filas sin `CustomerID`	24.93 %

Para determinar la fracción de filas sin identificador de cliente, se dividió la cantidad de registros con valores faltantes en `CustomerID` entre el número total de filas:

$$f_{\text{sin cliente}} = \frac{\text{Filas sin CustomerID}}{\text{Total de filas}}.$$

Sustituyendo los valores obtenidos:

$$\begin{aligned} f_{\text{sin cliente}} &= \frac{135080}{541909} \\ &\approx 0{,}249267. \end{aligned}$$

Expresando el resultado como porcentaje:

$$\boxed{f_{\text{sin cliente}} \approx 24{,}93\,\%}.$$

Esto indica que aproximadamente una cuarta parte de las líneas de factura no cuenta con un identificador de cliente. Esta situación es relevante porque, aunque dichos registros pueden contener información válida sobre ventas, no permiten asociar directamente las transacciones con un cliente específico.

Por esta razón, los registros sin `CustomerID` deberán evaluarse de manera diferente según el análisis que se realice. Para construir la serie temporal de ventas, podrían conservarse si representan transacciones válidas. En cambio, para el análisis de clientes de la Parte 6, será necesario disponer de un identificador que permita agrupar las compras de cada persona.

Conclusión La exploración inicial permitió identificar 541,909 líneas de factura, 25,900 facturas diferentes, 4,070 productos y 4,372 clientes. Asimismo, se encontró que el 24.93 % de los registros no contiene un identificador de cliente. Estos resultados constituyen el punto de partida para investigar las anomalías del conjunto de datos y definir las reglas de limpieza que se aplicarán posteriormente.

Investigación de anomalías

Antes de aplicar las reglas de limpieza, se investigaron seis tipos de anomalías presentes en el conjunto de datos original. El objetivo fue identificar su frecuencia, examinar ejemplos representativos y establecer decisiones justificadas para evitar la eliminación de transacciones legítimas.

La Tabla 11 presenta los resultados de la exploración. Las categorías no son mutuamente excluyentes, por lo que sus cantidades no deben sumarse para obtener el total de registros afectados.

Cuadro 11: Anomalías identificadas en el conjunto de datos original.

Anomalía	Filas identificadas
Duplicados exactos adicionales	5,268
Facturas con prefijos especiales	9,291
Códigos `StockCode` especiales	2,995
Precio unitario igual a cero	2,515
Precio unitario negativo	2
Cantidad negativa sin cancelación	1,336
Registros sin `CustomerID`	135,080

a) Filas duplicadas exactas

Se identificaron 5268 filas duplicadas adicionales, considerando todas las columnas del conjunto de datos. Estos registros contienen la misma información que una fila anterior,

incluyendo número de factura, producto, cantidad, precio, fecha y cliente.

Se propone eliminar las copias adicionales para evitar contabilizar repetidamente una misma línea de factura. Esta decisión supone que las filas idénticas corresponden a duplicaciones de registro y no a operaciones independientes que casualmente comparten todos sus atributos.

b) Facturas que no comienzan con un dígito

Se encontraron 9291 filas pertenecientes a facturas cuyos identificadores no comienzan con un dígito. De ellas, 9288 utilizan el prefijo `C` y tres utilizan el prefijo `A`.

Las facturas con prefijo `C` representan cancelaciones o devoluciones. Por ejemplo, la factura `C536391` contiene cantidades negativas de diferentes productos. Se decidió conservar estas transacciones porque permiten descontar las devoluciones al calcular las ventas netas.

Las tres facturas con prefijo `A` corresponden a ajustes de deuda identificados mediante la descripción `Adjust bad debt`. Estas operaciones no representan ventas ordinarias de productos, por lo que se propone excluirlas de la serie de ventas.

c) Códigos `StockCode` especiales

Se identificaron 2995 filas cuyos códigos no comienzan con cinco dígitos, correspondientes a 33 códigos diferentes. Entre los más frecuentes se encuentran `POST`, `DOT`, `M`, `C2`, `D`, `S`, `BANK CHARGES` y `AMAZONFEE`.

Estos códigos representan operaciones de naturaleza diferente. Por ejemplo, `POST` y `DOT` corresponden a gastos de envío, `D` identifica descuentos y `BANK CHARGES` representa cargos bancarios. También se encontraron códigos especiales asociados con artículos y vales de regalo, por lo que no todos deben considerarse inválidos.

Se decidió clasificar estos registros según su significado antes de aplicar cualquier exclusión. Para el análisis de ventas netas se propone conservar los cargos y descuentos comerciales que formen parte de las transacciones, mientras que los ajustes contables y movimientos internos deberán excluirse cuando no representen ingresos o devoluciones comerciales.

d) Precios iguales a cero o negativos

Se identificaron 2515 filas con precio unitario igual a cero y dos filas con precio negativo. Entre los registros de precio cero se encontraron movimientos sin descripción y sin identificador de cliente, mientras que los dos precios negativos corresponden a ajustes de deuda.

Para la construcción de una serie de ventas monetarias, se propone excluir los registros de precio cero porque no aportan ingresos y requieren distinguirse de las transacciones comerciales con importe positivo. Los precios negativos asociados con ajustes de deuda también se excluirán, ya que no representan devoluciones ordinarias.

e) Cantidades negativas sin factura de cancelación

Se encontraron 1336 filas con cantidades negativas en facturas que no utilizan el prefijo `C`. Entre las descripciones más frecuentes aparecen `check`, `damages`, `damaged`, `sold as set on dotcom` y registros sin descripción.

Estos ejemplos sugieren que una parte importante de las cantidades negativas corresponde a verificaciones, daños o ajustes de inventario, en lugar de devoluciones realizadas por clientes.

Por lo tanto, se propone excluir estos registros de la serie de ventas netas cuando correspondan a movimientos administrativos o de inventario, conservando las devoluciones comerciales identificadas mediante el prefijo `C`.

f) Registros sin identificador de cliente

Se encontraron 135080 filas sin `CustomerID`, equivalentes al 24.93 % del conjunto de datos original. De ellas, 383 pertenecen a facturas de cancelación y 134697 a facturas sin dicho prefijo.

La ausencia del identificador de cliente no implica necesariamente que una transacción sea inválida. Por ejemplo, se observaron registros con productos, cantidades y precios definidos, aunque no se conozca la identidad del comprador.

Por esta razón, se decidió conservar las transacciones comercialmente válidas sin `CustomerID` para calcular las ventas netas. Sin embargo, estos registros no podrán utilizarse para el análisis RFM de la Parte 6, porque dicho análisis requiere identificar y agrupar las compras de cada cliente.

Conclusión La investigación mostró que las anomalías del conjunto de datos tienen causas diferentes y no deben tratarse mediante una única regla de eliminación. Las cancelaciones son necesarias para calcular las ventas netas, mientras que los ajustes de deuda y los movimientos de inventario requieren un tratamiento distinto. Asimismo, los registros sin identificador de cliente pueden conservarse para el análisis de ventas, aunque no sean adecuados para la segmentación RFM. Estas decisiones servirán como base para construir una limpieza reproducible y documentar su impacto en el ejercicio siguiente.

Ejercicio 1.3: Bitácora de limpieza

A partir de las anomalías identificadas en el ejercicio anterior, se implementó un procedimiento de limpieza secuencial. Para cada regla se registró la cantidad de filas eliminadas, el importe monetario asociado con dichas filas y el número de registros restantes. El importe de cada línea se calculó multiplicando la cantidad de unidades por su precio unitario, conservando el signo para distinguir ventas, descuentos y devoluciones.

$$\text{Importe de la línea}_i = \text{Quantity}_i \times \text{UnitPrice}_i$$

Las reglas se aplicaron en un orden definido, de modo que cada registro eliminado se contabilizara una sola vez. Esto es importante porque una misma fila puede presentar varias

anomalías simultáneamente. Por ejemplo, un movimiento de inventario con cantidad negativa también puede tener un precio igual a cero.

La Tabla 12 presenta los resultados del procedimiento de limpieza aplicado.

Cuadro 12: Bitácora secuencial de limpieza del conjunto de datos Online Retail.

Regla aplicada	Filas eliminadas	Importe (£)
1. Duplicados exactos	5,268	21,740.98
2. Facturas con prefijo A	3	-11,062.06
3. Movimientos administrativos	150	-239,669.22
4. Precios no positivos o faltantes	2,509	0.00
5. Cantidades negativas sin cancelación	0	0.00
6. Datos esenciales faltantes	0	0.00
Total	**7,930**	**-228,990.30**

La primera regla eliminó 5268 duplicados exactos adicionales. Posteriormente, se excluyeron tres registros asociados con ajustes de deuda y 150 movimientos administrativos identificados mediante sus códigos o descripciones. La cuarta regla eliminó 2509 registros con precios no positivos o faltantes. Las dos últimas reglas no eliminaron filas adicionales porque los registros que cumplían esas condiciones ya habían sido retirados en pasos anteriores o no estaban presentes en el conjunto restante.

En particular, aunque durante la exploración inicial se encontraron 1336 filas con cantidades negativas sin prefijo de cancelación, ninguna fue eliminada por la quinta regla. Esto se explica por el carácter secuencial del procedimiento: los registros afectados ya habían sido excluidos mediante las reglas anteriores.

Resumen del procedimiento El conjunto original contenía 541909 filas, de las cuales se eliminaron 7930, conservándose 533979 registros. Asimismo, se mantuvieron 132443 filas sin identificador de cliente, dado que la ausencia de este campo no invalida necesariamente una transacción para el análisis de ventas.

El importe neto original fue de 9747747.93 libras esterlinas, mientras que el importe asociado con los registros eliminados fue de -228990.30 libras. Por lo tanto, el importe neto del conjunto resultante se calculó de la siguiente manera:

$$\begin{aligned} \text{Importe limpio} &= \text{Importe original} - \text{Importe eliminado} \\ &= 9747747{,}93 - (-228990{,}30) \\ &= \boxed{9976738{,}23\ £}. \end{aligned}$$

El aumento del importe neto después de la limpieza se debe a que las reglas excluyeron movimientos cuyo valor agregado era negativo, principalmente ajustes administrativos.

Este cambio no representa un incremento real de las ventas, sino una modificación en las operaciones consideradas dentro del análisis.

La bitácora permite identificar el efecto individual de cada regla y verificar que la suma de los importes eliminados concuerde con la diferencia entre el conjunto original y el conjunto limpio. Adicionalmente, los criterios de limpieza se evaluaron mediante el análisis de las transacciones de mayor magnitud, presentado en el ejercicio 1.4.

Ejercicio 1.4: Análisis de transacciones extremas

Con el objetivo de evaluar el efecto de las transacciones de mayor magnitud sobre la serie de ventas, se calcularon los importes de todas las líneas del conjunto original mediante el producto entre `Quantity` y `UnitPrice`. Posteriormente, se seleccionaron las seis observaciones con mayor valor absoluto, sin aplicar previamente ninguna regla de limpieza.

$$I_i = \text{Quantity}_i \times \text{UnitPrice}_i, \qquad |I_i| = |\text{Quantity}_i \times \text{UnitPrice}_i|$$

El valor absoluto se utilizó exclusivamente para identificar las operaciones extremas, mientras que el signo del importe se conservó para distinguir entre ventas y cancelaciones.

Cuadro 13: Seis líneas con mayor importe absoluto antes de la limpieza.

Factura	Código	Cantidad	Importe (£)
581483	23843	80,995	168,469.60
C581484	23843	-80,995	-168,469.60
541431	23166	74,215	77,183.60
C541433	23166	-74,215	-77,183.60
556444	22502	60	38,970.00
C556445	M	-1	-38,970.00

Investigación de las facturas y sus movimientos posteriores

Las seis transacciones identificadas forman tres parejas de operaciones con importes exactamente opuestos. Para investigar su relación, se examinaron los identificadores de cliente, códigos de producto, fechas y horas de emisión, así como las transacciones cercanas en el tiempo.

Primera pareja: facturas 581483 y C581484 El 9 de diciembre de 2011, a las 09:15 horas, se registró una venta de 80995 unidades del producto *PAPER CRAFT, LITTLE BIRDIE*, correspondiente al cliente 16446, por un importe de 168469.60 libras. Doce minutos después, a las 09:27 horas, se emitió la factura de cancelación C581484 por la misma cantidad de unidades, el mismo precio y un importe de -168469.60 libras. La coincidencia entre el cliente, producto, cantidad y precio permite identificar una compensación exacta entre ambas operaciones.

Segunda pareja: facturas 541431 y C541433 El 18 de enero de 2011, a las 10:01 horas, se registró una venta de 74215 unidades del producto *MEDIUM CERAMIC TOP STORAGE JAR*, correspondiente al cliente 12346, por 77183.60 libras. A las 10:17 horas del mismo día se emitió la cancelación C541433 por -77183.60 libras. Al igual que en el caso anterior, ambas operaciones corresponden al mismo cliente y producto, por lo que su efecto monetario conjunto es nulo.

Tercera pareja: facturas 556444 y C556445 El 10 de junio de 2011, a las 15:28 horas, se registró una venta de 60 unidades del producto *PICNIC BASKET WICKER 60 PIECES*, identificado mediante el código 22502, a un precio unitario de 649.50 libras. El importe total fue de 38970.00 libras. Tres minutos después se emitió la factura C556445, correspondiente al mismo cliente 15098, con un importe de -38970.00 libras.

En este caso, la cancelación utiliza el código especial `M` y la descripción *Manual*, en lugar del código original del producto. Por esta razón, una búsqueda basada únicamente en `StockCode` no habría identificado la relación entre ambas transacciones. La coincidencia del cliente, fecha e importe permite reconocer una compensación monetaria exacta.

La investigación también identificó otros movimientos del mismo cliente durante ese día. A las 15:22 horas se registró una operación por 297.00 libras, cancelada posteriormente a las 15:39 horas por -297.00 libras. Además, a las 15:33 horas apareció una nueva operación por 649.50 libras. Esta secuencia es compatible con correcciones o refacturaciones, aunque los datos disponibles no permiten establecer con certeza el motivo administrativo o comercial.

Efecto de la limpieza y de la agregación diaria

La función de limpieza conservó las seis líneas extremas. Esta decisión es coherente con el criterio de mantener las cancelaciones comerciales, ya que eliminar únicamente las ventas positivas o sus correspondientes devoluciones produciría una distorsión en el cálculo de las ventas netas.

Para evaluar el efecto de la agregación diaria, se sumaron los importes con su signo correspondiente dentro de cada fecha:

$$V_d = \sum_{i:\,\text{Fecha}_i = d} I_i$$

Las tres parejas identificadas se compensan exactamente dentro de sus respectivos días:

$$\begin{aligned} 168469{,}60 - 168469{,}60 &= 0{,}00, \\ 77183{,}60 - 77183{,}60 &= 0{,}00, \\ 38970{,}00 - 38970{,}00 &= 0{,}00. \end{aligned}$$

Cuadro 14: Ventas netas diarias antes y después de la limpieza.

Fecha	Original (£)	Limpio (£)
18/01/2011	18,680.80	18,635.48
10/06/2011	22,540.66	22,540.66
09/12/2011	32,131.53	32,111.91

Las diferencias entre los totales originales y limpios de enero y diciembre se deben a otras filas retiradas durante la limpieza, mientras que las seis operaciones extremas permanecieron en ambos conjuntos.

Conclusión La limpieza no elimina las seis transacciones extremas, pero tampoco necesita hacerlo, debido a que todas cuentan con movimientos compensatorios registrados el mismo día. La agregación diaria de ventas netas permite que sus importes positivos y negativos se anulen, evitando que estas parejas generen valores artificialmente elevados en la serie diaria.

Este resultado demuestra la importancia de conservar las cancelaciones y de analizar los movimientos relacionados antes de excluir observaciones únicamente por su magnitud. Sin embargo, la compensación observada depende de que ambas operaciones se registren dentro del mismo período de agregación; por ello, no debe suponerse que todas las transacciones extremas del conjunto se resolverán de la misma manera.

Ejercicio 1.5: Implementación de una función reutilizable de limpieza

Con el propósito de garantizar la reproducibilidad del procesamiento y facilitar su utilización en las siguientes partes de la tarea, se implementó una función denominada `limpiar(datos)`. Esta función recibe como argumento un DataFrame de pandas con las transacciones originales y devuelve un nuevo DataFrame después de aplicar las reglas de limpieza definidas en los ejercicios anteriores.

La implementación centraliza las operaciones de limpieza en un único procedimiento, evitando la necesidad de repetir manualmente las transformaciones cada vez que se utilice el conjunto de datos. Asimismo, se trabaja sobre una copia del DataFrame recibido para conservar intacta la información original.

El procedimiento aplica seis reglas en el siguiente orden: eliminación de duplicados exactos, exclusión de facturas con prefijo `A`, eliminación de movimientos administrativos, exclusión de precios no positivos o faltantes, eliminación de cantidades negativas que no correspondan a cancelaciones y descarte de registros sin información esencial para calcular las ventas.

Se decidió conservar las facturas con prefijo `C`, ya que representan cancelaciones cuyo importe negativo debe incluirse en el cálculo de ventas netas. Esta decisión fue respaldada por el análisis del ejercicio 1.4, donde las seis transacciones de mayor magnitud formaron tres parejas de operaciones que se compensaron exactamente al agregarse por día.

También se conservaron los registros sin `CustomerID`, debido a que la ausencia del identificador de cliente no impide calcular el importe de una transacción. Sin embargo, estos registros

deberán excluirse posteriormente cuando el análisis requiera identificar a cada cliente, como sucede en la Parte 6.

La función permite obtener opcionalmente una bitácora con las filas e importes eliminados por cada regla. Este comportamiento se controla mediante el parámetro `devolver_bitacora`, cuyo valor predeterminado es `False`. Por lo tanto, la función devuelve únicamente el DataFrame limpio cuando se utiliza de la forma solicitada en el enunciado.

Listing 1: Uso de la función reutilizable de limpieza.

```
datos = cargar_datos(ARCHIVO_DATOS)

datos_limpios = limpiar(datos)

datos_limpios, bitacora = limpiar(
    datos, devolver_bitacora=True
)
```

Validación de la función de limpieza Para comprobar que la función implementada puede reutilizarse de manera confiable, se realizaron tres verificaciones. Primero, se confirmó que su ejecución no modifica el DataFrame original, debido a que las operaciones se aplican sobre una copia de los datos. Segundo, se comprobó que ejecutar la función dos veces sobre el mismo conjunto de datos produce resultados idénticos. Finalmente, se verificó la idempotencia del procedimiento, es decir, que aplicar nuevamente la limpieza sobre un conjunto previamente depurado no modifica los registros resultantes.

Las tres comprobaciones devolvieron el valor `True`, lo que confirma que la función conserva los datos originales, produce resultados consistentes y mantiene un comportamiento estable ante ejecuciones repetidas. Por lo tanto, puede reutilizarse en las siguientes partes de la tarea sin necesidad de modificar las reglas de limpieza.

La ejecución del procedimiento sobre el conjunto de datos *Online Retail* produjo un DataFrame con 533979 registros, a partir de las 541909 filas originales. En total, se eliminaron 7930 filas mediante las reglas establecidas. El importe neto resultante fue de 9976738.23 libras esterlinas.

La función puede reutilizarse directamente en la construcción de la serie temporal de ventas y en los análisis posteriores, manteniendo criterios consistentes de depuración. Para los procedimientos que requieren información adicional, como la identificación de clientes, se podrán aplicar filtros específicos después de ejecutar la limpieza general, sin modificar las reglas originales.

De esta manera, la preparación de los datos queda definida mediante un procedimiento único, reproducible y verificable, que permite conservar la trazabilidad de las decisiones tomadas durante la limpieza.

1. Parte 2: El calendario

Ejercicio 2.1: Serie de venta neta diaria y días con transacciones

Para construir la serie temporal de ventas, se utilizó el conjunto de datos previamente depurado mediante la función `limpiar(datos)` desarrollada en la Parte 1. Para cada registro conservado, se calculó el importe de la transacción multiplicando `Quantity` por `UnitPrice`, manteniendo los importes negativos correspondientes a cancelaciones.

Posteriormente, se extrajo la fecha de cada factura a partir de `InvoiceDate`, eliminando únicamente la componente horaria. Los importes se agruparon por fecha y se sumaron para obtener la venta neta diaria. También se contabilizó el número de líneas de transacción registradas en cada día.

La serie resultante se incorporó a un calendario diario completo, desde el 1 de diciembre de 2010 hasta el 9 de diciembre de 2011, incluyendo ambas fechas. Este procedimiento permitió identificar los días sin registros de transacciones, conservándolos inicialmente como valores faltantes en lugar de asignarles automáticamente un importe de cero.

Los resultados obtenidos fueron los siguientes:

Cuadro 15: Resumen del calendario de ventas de Online Retail.

Indicador	**Resultado**
Primera fecha	01/12/2010
Última fecha	09/12/2011
Días calendario	374
Días con transacciones	305
Días sin transacciones	69

De los 374 días calendario comprendidos en el período de observación, 305 registraron al menos una transacción y 69 no presentaron movimientos. Estos resultados muestran que la serie de ventas no contiene observaciones para todos los días del calendario.

La identificación de estas fechas es importante porque la ausencia de transacciones no necesariamente implica un dato perdido. Algunos días pueden corresponder a cierres habituales de la tienda o a feriados. Por esta razón, se conservaron temporalmente como valores faltantes para investigar su significado en los ejercicios siguientes.

Ejercicio 2.2: Días cerrados, feriados y calendario del Reino Unido

A partir de la serie diaria construida en el ejercicio anterior, se identificaron las fechas sin registros de transacciones y se clasificaron según su día de la semana y su coincidencia con los feriados bancarios de Inglaterra y Gales durante el período de estudio. Para ello, se compararon las fechas del conjunto de datos con los calendarios históricos de feriados del Reino Unido.

De los 69 días sin transacciones, 53 correspondieron a sábados, nueve coincidieron con feriados bancarios y siete fueron fechas adicionales sin actividad. La ausencia de transacciones

en todos los sábados del período permite identificar este día como el cierre semanal habitual de la tienda.

Cuadro 16: Clasificación de los días sin transacciones.

Clasificación	**Cantidad de días**
Cierre semanal (sábado)	53
Feriados bancarios	9
Otros días sin transacciones	7
Total	69

Los nueve feriados bancarios sin transacciones fueron el 27 y 28 de diciembre de 2010, el 3 de enero de 2011, el 22, 25 y 29 de abril de 2011, el 2 y 30 de mayo de 2011 y el 29 de agosto de 2011. Estas fechas corresponden a feriados sustitutos de Navidad, Boxing Day y Año Nuevo, Viernes Santo, Lunes de Pascua, la boda real del príncipe William y Catherine Middleton, y los feriados bancarios de mayo y agosto.

Los siete días restantes fueron el 24, 26, 29, 30 y 31 de diciembre de 2010, el 2 de enero de 2011 y el 24 de abril de 2011. Estas fechas se concentran alrededor de las celebraciones de Navidad, Año Nuevo y Semana Santa, por lo que son compatibles con períodos especiales de cierre. Sin embargo, los datos no permiten confirmar de manera independiente las razones administrativas de cada ausencia.

Entre los feriados móviles se encuentran Viernes Santo y Lunes de Pascua, cuyas fechas dependen de la celebración de Semana Santa. También cambian de fecha numérica los feriados bancarios establecidos según determinados lunes de mayo y agosto, así como los días sustitutos cuando las festividades coinciden con fines de semana. Por otra parte, el 29 de abril de 2011 fue declarado feriado extraordinario con motivo de la boda real, por lo que no constituye una festividad recurrente.

La clasificación muestra que los días sin transacciones responden principalmente a un patrón semanal de cierre y a interrupciones asociadas con el calendario festivo. Esta información será necesaria para distinguir entre ventas iguales a cero y observaciones faltantes en el siguiente ejercicio.

Ejercicio 2.3: Decisión entre cero y dato faltante

La ausencia de transacciones en una fecha no debe interpretarse automáticamente como un valor de venta igual a cero. La representación adecuada depende del objetivo del análisis y de si la tienda se encontraba operando durante ese día.

Cuando el propósito es calcular las ventas totales de un período calendario, como una semana o un mes, los días en que la tienda permaneció cerrada pueden representarse con cero. Esto permite mantener todos los días del período y refleja que no se generaron ingresos durante esas fechas. Por ejemplo, para calcular las ventas totales de la semana que incluye el sábado 4 de diciembre de 2010, dicho día puede contribuir con un importe de cero.

Por otra parte, cuando se busca analizar o pronosticar las ventas correspondientes a días de operación, los días cerrados deben tratarse como datos faltantes. Esto se debe a que no representan observaciones de la actividad comercial habitual y su inclusión como ceros podría reducir artificialmente el promedio de ventas y distorsionar los patrones utilizados para ajustar los modelos.

Es importante distinguir esta situación de un día en el que sí hubo transacciones, pero cuya suma neta fue exactamente cero. En ese caso, el cero corresponde a una observación válida y debe conservarse como tal.

Por lo tanto, para los análisis posteriores de esta tarea se mantendrá el calendario diario completo, identificando los días cerrados mediante valores faltantes. Esta decisión sigue la indicación del enunciado y permite trabajar con las ventas de los días abiertos sin confundir los cierres comerciales con ventas efectivamente observadas.

Revisión del último día de observación

Se examinó el último día disponible en el conjunto de datos, correspondiente al 9 de diciembre de 2011, con el objetivo de determinar si contenía un registro completo de la actividad comercial. Para ello, se identificaron las horas de la primera y última transacción, el número de líneas registradas, la cantidad de facturas distintas y el importe neto de ventas.

Los resultados mostraron que la primera transacción del 9 de diciembre ocurrió a las 08:39 y la última a las 12:50. Durante ese intervalo se registraron 1,625 líneas de transacción, correspondientes a 49 facturas distintas, con una venta neta de 32,111.91 libras esterlinas.

En comparación, el 8 de diciembre registró transacciones desde las 08:32 hasta las 20:01, con 4,901 líneas, 140 facturas distintas y una venta neta de 81,294.33 libras esterlinas.

Cuadro 17: Comparación de los dos últimos días del conjunto de datos.

Indicador	**08/12/2011**	**09/12/2011**
Primera transacción	08:32	08:39
Última transacción	20:01	12:50
Líneas de transacción	4,901	1,625
Facturas distintas	140	49
Venta neta (GBP)	81,294.33	32,111.91

La finalización de los registros a las 12:50, considerablemente antes de las últimas transacciones observadas en los días anteriores, junto con la reducción en la cantidad de facturas y ventas, sugiere que el 9 de diciembre contiene información parcial de la jornada.

Por esta razón, se decidió excluir esta fecha de la serie utilizada en los análisis posteriores. Mantenerla podría introducir una disminución artificial de las ventas y afectar la estimación de los modelos de pronóstico.

La serie definitiva comprende desde el 1 de diciembre de 2010 hasta el 8 de diciembre de 2011, con 373 días calendario, de los cuales 69 no registraron transacciones. Los días de cierre se conservaron como valores faltantes, de acuerdo con el criterio establecido en el

ejercicio anterior. El archivo original y los resultados de la limpieza inicial permanecieron sin modificaciones.

2. Parte 3: Tendencia, estacionalidad y autocorrelación

Media móvil centrada de siete días

Para analizar la tendencia de las ventas, se calculó una media móvil centrada de siete días sobre la serie diaria preparada en la Parte 2. Esta serie comprende desde el 1 de diciembre de 2010 hasta el 8 de diciembre de 2011, con 373 días calendario, de los cuales 304 presentan ventas observadas y 69 corresponden a días sin transacciones.

La media móvil permite suavizar las fluctuaciones diarias y observar con mayor claridad los cambios en el nivel general de las ventas. Para cada fecha se consideró una ventana de siete días calendario, formada por los tres días anteriores, el día central y los tres días posteriores.

Debido a que los días cerrados se conservaron como valores faltantes, el promedio se calculó utilizando únicamente las observaciones disponibles dentro de cada ventana. En los extremos de la serie se utilizaron las fechas disponibles, sin exigir una ventana completa de siete días.

La media móvil se calculó mediante la siguiente expresión:

$$MM_7(t) = \frac{\sum_{j=-3}^{3} Y_{t+j} I_{t+j}}{\sum_{j=-3}^{3} I_{t+j}}$$

donde Y_{t+j} representa la venta neta diaria e I_{t+j} es un indicador que toma el valor de uno cuando existe una observación de ventas y cero cuando el día no presenta transacciones. La expresión se aplica cuando existe al menos una observación disponible en la ventana.

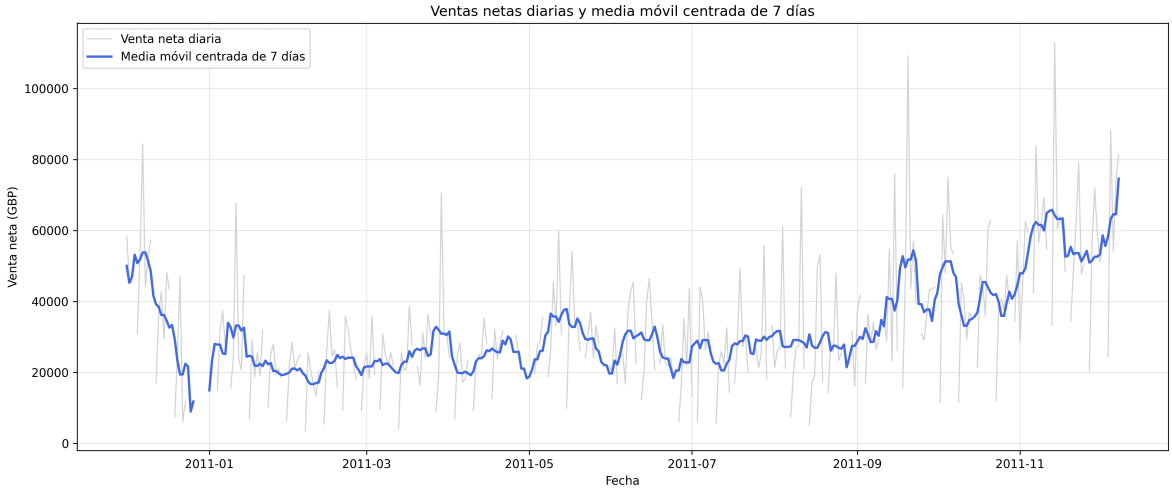


Figura 4: Ventas netas diarias y media móvil centrada de siete días.

Como se observa en la Figura 4, las ventas diarias presentan fluctuaciones importantes, mientras que la media móvil permite identificar una trayectoria más estable.

Durante diciembre de 2010 y principios de enero de 2011 se observa una disminución del nivel de ventas, acompañada de una interrupción de la línea suavizada debido a varios días consecutivos sin transacciones. Posteriormente, entre febrero y agosto de 2011, la tendencia se mantiene relativamente estable, con oscilaciones moderadas.

A partir de septiembre de 2011 se aprecia un incremento progresivo de las ventas, que se vuelve más pronunciado durante noviembre y principios de diciembre. En este último período, la media móvil supera las 60,000 libras esterlinas en algunas fechas.

Estos resultados sugieren un aumento de la actividad comercial hacia el final del período analizado. Sin embargo, dado que el conjunto de datos abarca aproximadamente un año, no es posible establecer únicamente a partir de esta gráfica si dicho comportamiento constituye un patrón estacional recurrente.

Índices estacionales por día de la semana

Con el propósito de identificar diferencias en el comportamiento de las ventas según el día de la semana, se calcularon índices estacionales multiplicativos a partir de la serie diaria preparada en la Parte 2.

Para este análisis se utilizaron únicamente los 304 días con ventas observadas, excluyendo los días de cierre y las fechas sin transacciones. El promedio general de ventas fue de 32,712.59 libras esterlinas.

Los índices se calcularon dividiendo el promedio de ventas correspondiente a cada día de la semana entre el promedio general de ventas observadas:

$$I_d = \frac{\overline{Y}_d}{\overline{\overline{Y}}}$$

donde $\overline{Y}_d$ representa el promedio de ventas del día de la semana d y $\overline{Y}$ corresponde al promedio general de los días con actividad.

Un índice superior a uno indica que las ventas promedio del día se encuentran por encima del promedio general, mientras que un índice inferior a uno indica un nivel de ventas menor.

Cuadro 18: Índices estacionales de ventas por día de la semana.

Día	**Días observados**	**Índice**	**Diferencia (%)**
Lunes	47	1.0860	+8.60
Martes	52	1.1865	+18.65
Miércoles	53	1.0313	+3.13
Jueves	53	1.2255	+22.55
Viernes	49	0.9640	-3.60
Sábado	0	–	–
Domingo	50	0.4883	-51.17

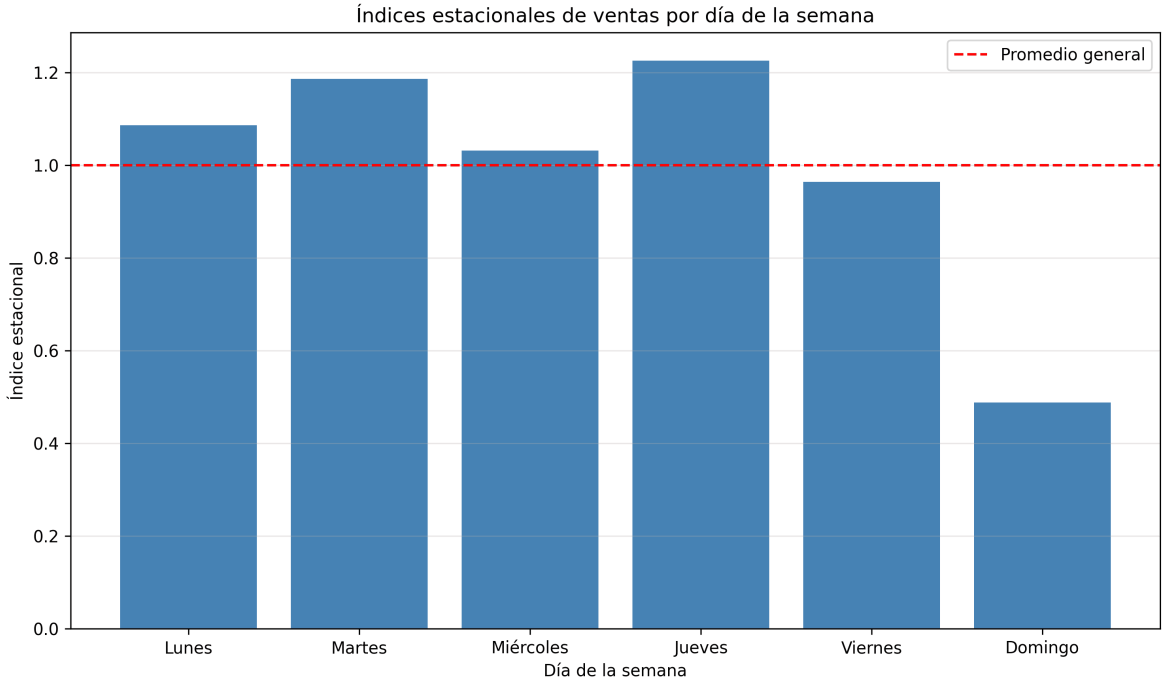


Figura 5: Índices estacionales de ventas netas por día de la semana.

Como se observa en la Tabla 18 y en la Figura 5, los jueves presentan el mayor índice estacional, con un valor de 1.2255, equivalente a ventas promedio aproximadamente un 22.55 % superiores al promedio general. Los martes también muestran un nivel elevado, con un índice de 1.1865.

Por otra parte, los domingos presentan el menor índice, con un valor de 0.4883, lo que representa ventas promedio aproximadamente un 51.17 % inferiores al promedio general. Los viernes también se encuentran ligeramente por debajo del promedio, con un índice de 0.9640.

Los sábados no cuentan con un índice estimable, debido a que no registraron transacciones durante el período estudiado. Por esta razón, se excluyeron del cálculo en lugar de asignarles un valor de cero.

Los resultados evidencian diferencias en el nivel promedio de ventas según el día de la semana. Sin embargo, estos índices son descriptivos y no fueron ajustados previamente por tendencia, por lo que parte de las diferencias observadas podría estar influida por la evolución temporal de las ventas.

Autocorrelación y prueba de Ljung–Box

Para analizar la dependencia temporal de las ventas netas diarias, se calculó la función de autocorrelación (ACF) hasta un máximo de 21 rezagos, con el propósito de identificar posibles relaciones entre las ventas de diferentes fechas y evaluar la presencia de un patrón semanal.

La serie utilizada comprende 373 días calendario, de los cuales 304 contienen ventas observadas y 69 corresponden a fechas sin transacciones. Debido a que los días cerrados se conservaron como valores faltantes, las autocorrelaciones se estimaron utilizando únicamente los pares de observaciones disponibles para cada rezago, sin eliminar fechas del calendario ni sustituir los valores faltantes por ceros.

Para cada rezago k, se calculó la covarianza de los pares válidos y se dividió entre la varianza de las ventas observadas. De esta manera, los rezagos representan separaciones reales en días calendario.

Como referencia visual, se utilizaron bandas aproximadas del 95 %, calculadas mediante:

$$\pm\frac{1{,}96}{\sqrt{n}}$$

donde $n = 304$ corresponde a la cantidad de días con ventas observadas. Las bandas resultantes fueron aproximadamente $\pm 0{,}1124$. Debido a la presencia de observaciones faltantes, estas bandas se consideran referencias exploratorias y no intervalos de confianza exactos.

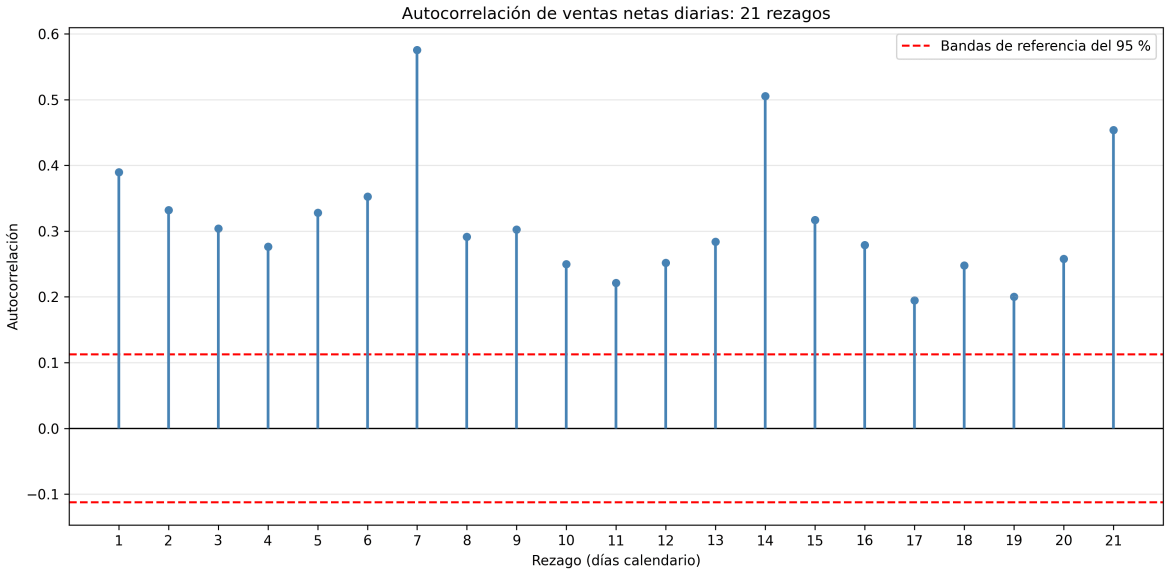


Figura 6: Función de autocorrelación de las ventas netas diarias hasta 21 rezagos, con bandas de referencia aproximadas del 95 %.

Como se observa en la Figura 6, las autocorrelaciones son positivas en los 21 rezagos analizados y superan las bandas de referencia. Destacan especialmente los rezagos 7, 14 y 21, con autocorrelaciones de 0.5753, 0.5052 y 0.4537, respectivamente.

Estos resultados sugieren la presencia de una estructura semanal en las ventas, ya que los valores más elevados aparecen en separaciones de una, dos y tres semanas. Este comportamiento es consistente con las diferencias entre días de la semana identificadas en el ejercicio anterior.

Adicionalmente, se calcularon estadísticos de Ljung–Box de manera exploratoria, utilizando las autocorrelaciones estimadas para evaluar conjuntamente la dependencia hasta distintos números de rezagos.

La hipótesis nula de la prueba convencional establece que las autocorrelaciones poblacionales hasta el rezago considerado son iguales a cero:

$$H_0 : \rho_1 = \rho_2 = \cdots = \rho_h = 0$$

Mientras que la hipótesis alternativa establece que al menos una de estas autocorrelaciones es distinta de cero:

$$H_1 : \exists\, k \leq h \text{ tal que } \rho_k \neq 0$$

El estadístico utilizado fue:

$$Q(h) = n(n+2) \sum_{k=1}^{h} \frac{\widehat{\rho}_k^2}{n-k}$$

donde n es el número de observaciones con ventas, h es el número de rezagos considerados y $\widehat{\rho}_k$ representa la autocorrelación estimada en el rezago k.

Cuadro 19: Estadísticos exploratorios de Ljung–Box.

Rezagos	**Estadístico Q**	**Valor p de referencia**
7	308.65	$8{,}59 \times 10^{-63}$
14	527.20	$1{,}58 \times 10^{-103}$
21	719.50	$1{,}00 \times 10^{-138}$

Los estadísticos obtenidos aumentan conforme se incorporan más rezagos, mientras que los valores p de referencia son considerablemente inferiores a 0.05. Bajo las condiciones habituales de la prueba de Ljung–Box, estos resultados serían incompatibles con la hipótesis nula de ausencia de autocorrelación.

Sin embargo, debido a que la serie contiene días sin observaciones y las autocorrelaciones fueron estimadas mediante pares disponibles, no se garantiza que los estadísticos calculados sigan la distribución chi-cuadrado convencional. Por esta razón, los valores p se interpretan únicamente como referencias exploratorias y no como resultados de una prueba formal exacta.

En conjunto, la ACF y los estadísticos exploratorios muestran una dependencia temporal importante, especialmente en los rezagos múltiplos de siete. Esto sugiere que el comportamiento de las ventas está relacionado con el calendario semanal. No obstante, parte de las autocorrelaciones también podría estar influida por la tendencia general de la serie.

3. Parte 4: Del AR(1) al SARIMA

En esta parte se analizaron distintos modelos para representar la dependencia temporal de las ventas netas diarias. Se utilizó el período de entrenamiento comprendido entre el 1

de diciembre de 2010 y el 30 de septiembre de 2011, con un total de 245 días con ventas observadas.

Regresión OLS por día de la semana

Se ajustó una regresión por mínimos cuadrados ordinarios (OLS) para evaluar la relación entre el día de la semana y las ventas netas diarias. Se utilizaron variables indicadoras para los seis días con actividad comercial, sin incluir intercepto.

El modelo se expresa como:

$$Y_t = \sum_{d \in D} \beta_d I_{d,t} + \varepsilon_t,$$

donde Y_t representa la venta neta del día t, $I_{d,t}$ indica si la observación corresponde al día d y β_d representa la venta promedio estimada para ese día de la semana.

Los coeficientes obtenidos fueron:

Cuadro 20: Ventas promedio estimadas mediante regresión OLS

Día	**Venta estimada (£)**
Lunes	27,770.41
Martes	35,966.22
Miércoles	28,504.25
Jueves	36,093.53
Viernes	27,106.35
Domingo	13,819.45

El coeficiente de determinación fue $R^2 = 0{,}2606$ y el coeficiente ajustado fue $R^2_{\text{ajustado}} = 0{,}2451$. Esto indica que el día de la semana explica aproximadamente el 26.06 % de la variabilidad de las ventas.

Los jueves y martes presentaron las mayores ventas promedio, mientras que los domingos registraron las menores.

Para determinar si la regresión eliminó la dependencia temporal, se calculó la función de autocorrelación (ACF) de sus residuos, conservando los días sin observaciones en el calendario.

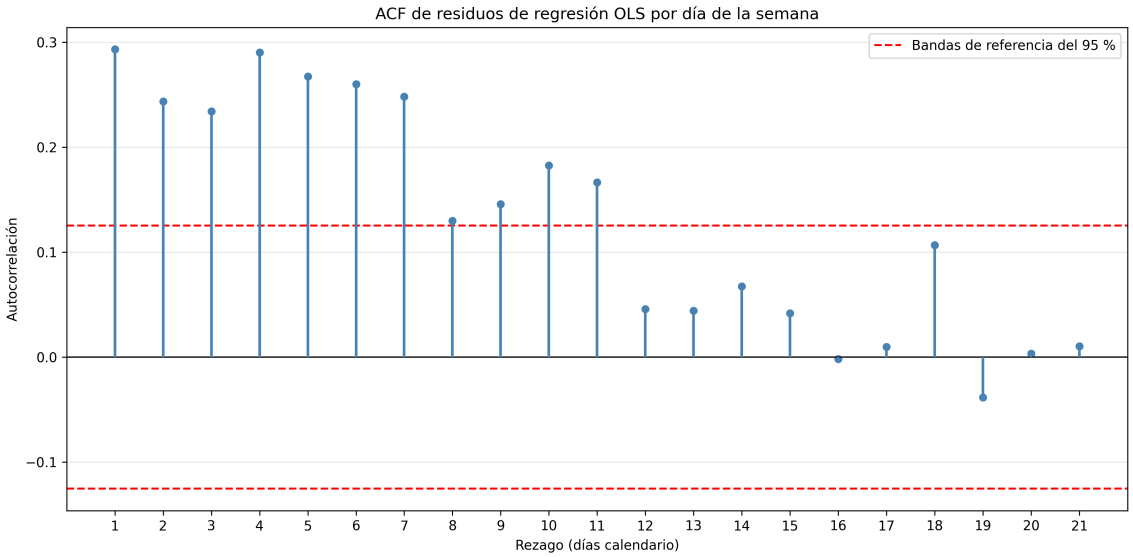


Figura 7: Autocorrelación de los residuos de la regresión OLS.

En la Figura 7 se observan autocorrelaciones positivas que superan las bandas de referencia del 95 %, especialmente en los primeros rezagos.

Por tanto, aunque el modelo OLS captura diferencias entre los días de la semana, sus residuos todavía presentan dependencia temporal que no es explicada por las variables indicadoras.

Modelo AR(1) sobre los residuos OLS

Para analizar la dependencia temporal restante se ajustó un modelo autorregresivo de primer orden sobre los residuos obtenidos mediante OLS.

El modelo se expresa como:

$$e_t = c + \phi e_{t-1} + u_t,$$

donde e_t es el residuo de la regresión OLS, c es el intercepto, ϕ es el coeficiente autorregresivo y u_t representa la innovación del modelo.

Se utilizaron 199 pares de días calendario consecutivos con residuos observados. Los parámetros estimados fueron:

$$\hat{c} = 74{,}4557, \tag{1}$$

$$\hat{\phi} = 0{,}2735. \tag{2}$$

El coeficiente autorregresivo fue positivo y estadísticamente significativo, con un valor $p < 0{,}001$. Esto indica que existe dependencia positiva entre los residuos de días calendario consecutivos.

El modelo obtuvo un coeficiente de determinación $R^2 = 0{,}0745$.

Posteriormente se calculó la ACF de las innovaciones para evaluar si el AR(1) había eliminado la dependencia temporal.

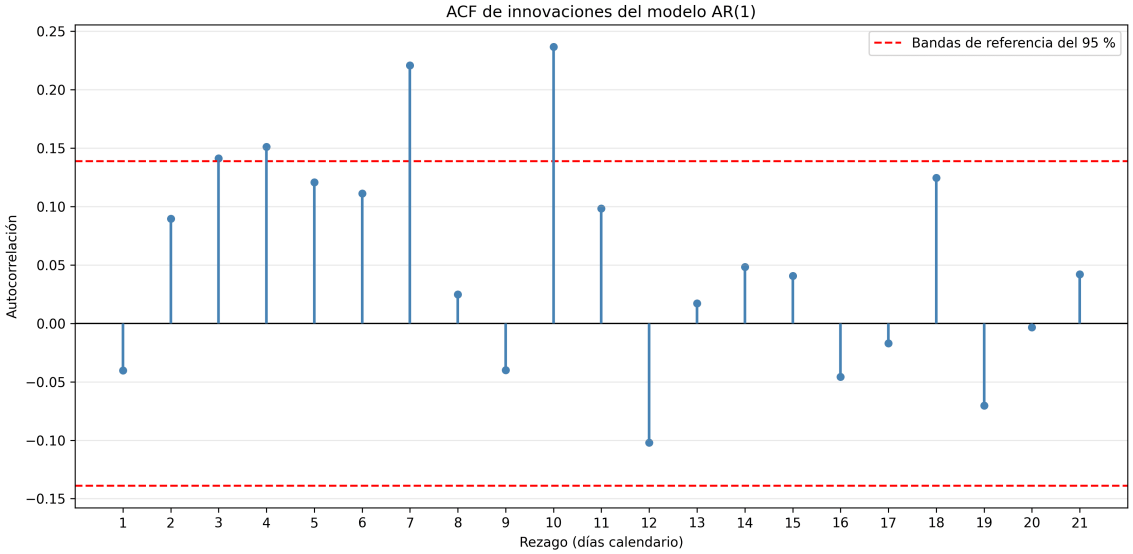


Figura 8: Autocorrelación de las innovaciones del modelo AR(1).

En la Figura 8, la autocorrelación del primer rezago se encuentra cerca de cero. Sin embargo, varios rezagos posteriores superan las bandas de referencia.

Se realizó también un diagnóstico exploratorio mediante el estadístico de Ljung–Box, utilizando autocorrelaciones calculadas a partir de pares válidos del calendario.

Cuadro 21: Diagnóstico exploratorio de Ljung–Box para AR(1)

Rezago	Estadístico Q	gl	Valor p
6	16.2657	5	0.006125
12	43.0399	11	0.000011

Ambos valores p son inferiores a 0.05, lo que proporciona evidencia exploratoria de autocorrelación residual.

Debido a que existen días sin observaciones y las autocorrelaciones se estimaron con diferentes cantidades de pares válidos, estos valores se interpretan como referencias diagnósticas y no como una prueba exacta bajo los supuestos habituales de Ljung–Box.

En consecuencia, el AR(1) captura parte de la dependencia temporal, pero no elimina completamente la estructura presente en los residuos.

Ajuste de modelos SARIMA

Se ajustaron dos modelos SARIMA para representar tanto la dependencia temporal como el comportamiento estacional de las ventas.

Para estos modelos se consideraron únicamente los días con ventas observadas y se aplicó una transformación logarítmica:

$$Z_t = \ln(Y_t).$$

Se verificó que todas las ventas utilizadas fueran estrictamente positivas. En el período de entrenamiento, la venta mínima fue de £3,439.67 y la máxima de £109,228.08.

Se utilizaron los siguientes modelos:

$$S1 : \text{SARIMA}(1,0,0)(1,0,0)_6, \tag{3}$$

$$S2 : \text{SARIMA}(0,1,1)(0,1,1)_6. \tag{4}$$

El período estacional de seis observaciones corresponde a una semana comercial de seis días con actividad registrada.

El modelo S1 incluye un término autorregresivo ordinario y otro estacional, además de una constante. El modelo S2 incorpora diferenciación ordinaria y estacional, junto con términos de medias móviles.

Ambos modelos convergieron durante el ajuste.

Cuadro 22: Comparación de los modelos SARIMA

Modelo	**AIC**	**BIC**	**Convergencia**
S1	330.6882	344.6932	Sí
S2	320.3764	330.7933	Sí

El modelo S2 obtuvo valores inferiores de AIC y BIC. Por lo tanto, de acuerdo con estos criterios de información, S2 presenta un mejor equilibrio entre ajuste y complejidad para los datos de entrenamiento.

Sin embargo, esta comparación no demuestra por sí sola que S2 tenga un menor error de pronóstico fuera de muestra. Esa evaluación se realizará en la Parte 5.

Diagnóstico de residuos SARIMA

Se analizaron las autocorrelaciones de los residuos de ambos modelos y se aplicó la prueba de Ljung–Box en los rezagos 6 y 12, descontando dos parámetros autorregresivos o de medias móviles estimados.

Modelo SARIMA S1

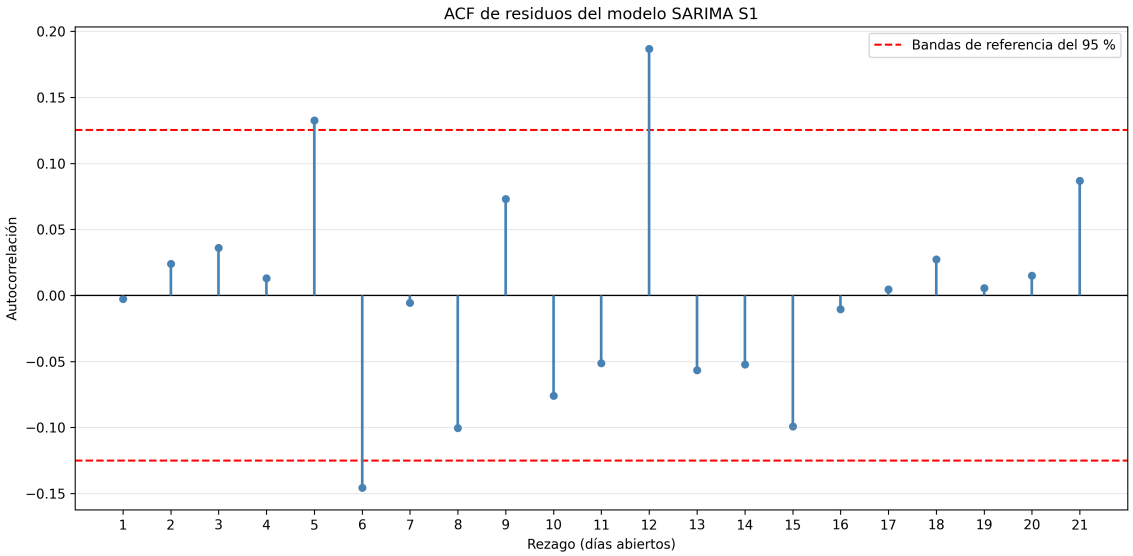


Figura 9: Autocorrelación de los residuos del modelo SARIMA S1.

La Figura 9 muestra autocorrelaciones que superan las bandas de referencia, particularmente en los rezagos 5, 6 y 12.

Modelo SARIMA S2

Para el diagnóstico del modelo S2 se descartaron los primeros siete residuos, correspondientes a la etapa inicial de diferenciación ordinaria y estacional.

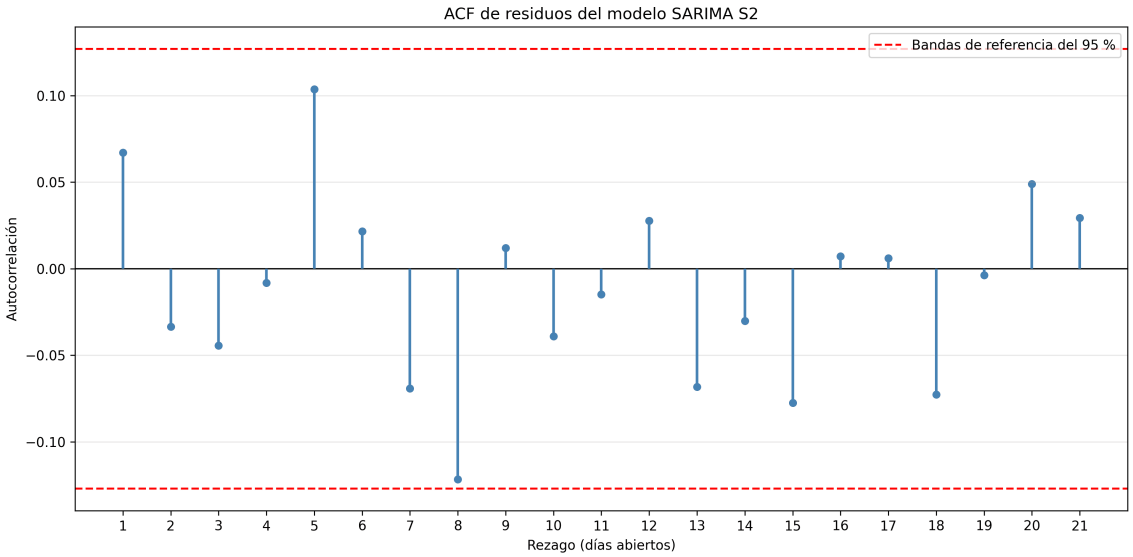


Figura 10: Autocorrelación de los residuos del modelo SARIMA S2.

En la Figura 10, las autocorrelaciones observadas se mantienen dentro de las bandas de referencia del 95 %, lo que sugiere una reducción importante de la dependencia temporal.

Los resultados de Ljung–Box fueron:

Cuadro 23: Prueba de Ljung–Box para los modelos SARIMA

Modelo	**Rezago**	**Q**	**gl**	**Valor p**
S1	6	9.7803	4	0.044296
S1	12	23.4107	10	0.009328
S2	6	4.5063	4	0.341802
S2	12	9.7974	10	0.458440

Para S1, ambos valores p son inferiores a 0.05. Por tanto, se rechaza la hipótesis nula de ausencia de autocorrelación conjunta hasta los rezagos evaluados.

Para S2, los valores p son superiores a 0.05. En consecuencia, no se rechaza la hipótesis nula, lo que indica que no se detecta autocorrelación significativa mediante esta prueba.

Estos resultados favorecen al modelo S2 en términos de diagnóstico de residuos.

Interpretación de pronósticos a largo plazo

Se generaron pronósticos para 60 días abiertos a partir de ambos modelos SARIMA, junto con intervalos de confianza del 95 %.

Los pronósticos se presentan en la escala logarítmica utilizada durante el ajuste.

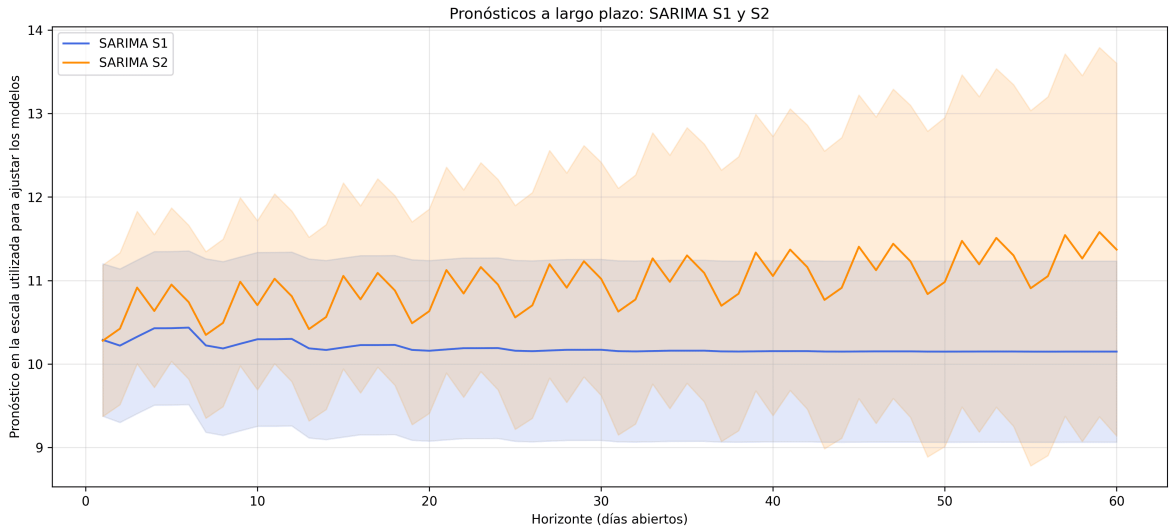


Figura 11: Pronósticos a largo plazo e intervalos del 95 % para los modelos SARIMA S1 y S2.

Cuadro 24: Pronósticos seleccionados en escala logarítmica

Horizonte	**S1**	**S2**
1	10.2892	10.2791
7	10.2230	10.3490
14	10.1686	10.5632
30	10.1710	11.0211
60	10.1492	11.3703

En la Figura 11 se observa que los pronósticos de S1 tienden a estabilizarse alrededor de 10.15 en escala logarítmica.

En cambio, S2 presenta oscilaciones periódicas y una trayectoria creciente, asociadas a su estructura de diferenciación y medias móviles estacionales.

La amplitud del intervalo de confianza en el horizonte 60 fue de 2.1684 para S1 y 4.4615 para S2, ambas medidas en escala logarítmica.

Esto indica que la incertidumbre de S2 aumenta más rápidamente conforme se amplía el horizonte de pronóstico.

En conjunto, S2 presenta mejores criterios de información y mejores diagnósticos de residuos, mientras que S1 produce pronósticos más estables a largo plazo.

La selección definitiva del modelo se realizará mediante la comparación de errores fuera de muestra, utilizando las métricas MAE y RMSE en la Parte 5.

4. Parte 5: Pronósticos y evaluación de modelos

Implementación de los modelos de pronóstico

Se implementaron seis modelos para pronosticar las ventas netas diarias del conjunto de datos *Online Retail*, con el objetivo de comparar métodos de referencia, modelos de regresión y modelos de series de tiempo. Se consideró el comportamiento semanal de las ventas y la disponibilidad de información al momento de generar cada pronóstico.

El período de entrenamiento comprendió las observaciones disponibles hasta el 30 de septiembre de 2011, mientras que el período de prueba abarcó del 3 de octubre al 8 de diciembre de 2011. Los días de cierre se conservaron como valores faltantes y se excluyeron del cálculo de las métricas. Asimismo, se eliminó el 9 de diciembre de 2011 debido a que correspondía a un día incompleto.

Los modelos implementados fueron los siguientes:

- **B1: Promedio histórico.** Utiliza la media de todas las ventas observadas hasta el origen del pronóstico. Este método proporciona una referencia sencilla que no incorpora explícitamente tendencias ni patrones semanales.
- **B2: Último día equivalente.** Utiliza la venta más reciente correspondiente al mismo día de la semana que se desea pronosticar. De esta manera, considera las diferencias de comportamiento entre los días de operación.
- **M1: Regresión lineal.** Incorpora una tendencia temporal expresada en días calendario y variables indicadoras del día de la semana, utilizando el lunes como categoría de referencia.
- **M2: Regresión con rezagos.** Incorpora variables indicadoras del día de la semana y rezagos de 7 y 14 días calendario. Cuando una fecha de rezago corresponde a un día cerrado, se busca una observación anterior del mismo día de la semana.
- **S1: SARIMA** $(1,0,0)(1,0,0)_6$**.** Se ajusta sobre el logaritmo de las ventas e incorpora componentes autorregresivos regulares y estacionales, además de una constante.
- **S2: SARIMA** $(0,1,1)(0,1,1)_6$**.** Se ajusta sobre el logaritmo de las ventas e incorpora diferenciación regular y estacional, junto con componentes de medias móviles, sin incluir una constante.

En los modelos SARIMA se utilizó una periodicidad estacional de seis observaciones, correspondiente a los días de operación de una semana habitual. Los días cerrados no se incluyeron como observaciones en estos modelos y los pronósticos obtenidos en escala logarítmica se transformaron nuevamente a la escala original de ventas mediante la función exponencial.

Para la evaluación temporal se empleó un esquema de origen móvil semanal. En cada domingo se utilizó únicamente la información disponible hasta esa fecha para ajustar los

modelos y generar los pronósticos correspondientes a los días abiertos de la semana siguiente. Este procedimiento permitió simular las condiciones de operación de un sistema de pronóstico que se actualiza periódicamente.

Evaluación mediante distintos esquemas de validación

Se utilizaron tres procedimientos de evaluación: validación cruzada aleatoria, validación temporal durante el período de entrenamiento y evaluación temporal sobre el período de prueba. La comparación permitió analizar cómo influye el esquema de validación en la estimación del desempeño predictivo.

Las métricas utilizadas fueron el error absoluto medio (*Mean Absolute Error*, MAE) y la raíz del error cuadrático medio (*Root Mean Squared Error*, RMSE), definidas mediante las ecuaciones 5 y 6.

$$MAE = \frac{1}{n}\sum_{t=1}^{n}|y_t - \hat{y}_t| \tag{5}$$

$$RMSE = \sqrt{\frac{1}{n}\sum_{t=1}^{n}(y_t - \hat{y}_t)^2} \tag{6}$$

Donde y_t representa la venta real, $\hat{y}_t$ corresponde al valor pronosticado y n es la cantidad de observaciones evaluadas. Ambas métricas se expresaron en libras esterlinas y se interpretaron considerando que los valores menores representan errores de pronóstico más bajos.

Validación cruzada aleatoria

Se aplicó una validación cruzada aleatoria de cinco particiones utilizando diez semillas diferentes. Este procedimiento se realizó únicamente para los modelos B1, M1 y M2, con el propósito de obtener una referencia de desempeño mediante particiones aleatorias de las observaciones del período de entrenamiento.

Para cada semilla se dividieron aleatoriamente las observaciones en cinco grupos. En cada iteración se ajustaron los modelos utilizando cuatro grupos y se evaluaron sobre el grupo restante. Posteriormente, se agruparon las predicciones de las cinco particiones para calcular el MAE y RMSE de cada semilla, obteniendo finalmente la media y la desviación estándar de las métricas entre las diez ejecuciones.

En M2, los rezagos de las fechas de validación se construyeron utilizando únicamente las observaciones disponibles en la partición de entrenamiento. Las fechas que no contaban con los rezagos necesarios se excluyeron, y los tres modelos se evaluaron sobre las mismas fechas válidas para mantener una comparación consistente.

Cuadro 25: Resultados de la validación cruzada aleatoria de cinco particiones y diez semillas

Modelo	MAE medio	Desv. MAE	RMSE medio	Desv. RMSE
B1	9984.37	66.33	13879.71	51.72
M1	8702.13	123.52	11827.59	118.86
M2	8567.25	180.20	11969.17	135.66

Como se observa en la Tabla 25, M2 presentó el menor MAE promedio, con 8567.25 libras esterlinas, mientras que M1 obtuvo el menor RMSE promedio, con 11827.59 libras esterlinas. Esto indica que la selección del modelo puede variar dependiendo de la métrica utilizada, debido a que el RMSE penaliza con mayor intensidad los errores de mayor magnitud.

Aunque este procedimiento permite comparar los modelos mediante múltiples particiones, presenta una limitación importante para el análisis de series de tiempo: las observaciones se distribuyen aleatoriamente y, por lo tanto, la evaluación no reproduce estrictamente una situación en la que únicamente se dispone de información anterior a la fecha pronosticada.

Validación temporal durante el entrenamiento

Se implementó una validación temporal con origen móvil semanal durante el período comprendido entre mayo y septiembre de 2011. En cada origen se ajustaron nuevamente los seis modelos utilizando las observaciones disponibles hasta el domingo correspondiente y se pronosticaron las ventas de los días abiertos de la semana siguiente.

Este procedimiento generó un total de 129 pronósticos diarios por modelo. Las métricas se calcularon agrupando los errores de todas las observaciones evaluadas, en lugar de promediar las métricas obtenidas individualmente por semana.

Cuadro 26: Resultados de la validación temporal durante el entrenamiento

Modelo	MAE (£)	RMSE (£)
B1	10576.23	15292.49
B2	11588.09	15895.25
M1	10044.12	14209.21
M2	9397.75	13597.23
S1	9932.26	14090.71
S2	10384.77	14385.79

Los resultados de la Tabla 26 muestran que M2 obtuvo los menores valores de MAE y RMSE, con 9397.75 y 13597.23 libras esterlinas, respectivamente. Esto sugiere que la combinación de indicadores semanales y rezagos históricos fue útil para representar el comportamiento de las ventas durante el período evaluado.

A diferencia de la validación aleatoria, el esquema de origen móvil respetó el orden cronológico de las observaciones y evitó que los modelos utilizaran ventas posteriores al origen

del pronóstico. Por esta razón, constituye una evaluación más cercana a las condiciones de uso real de los modelos.

Evaluación temporal sobre el período de prueba

Se aplicó el mismo procedimiento de origen móvil semanal al período comprendido entre el 3 de octubre y el 8 de diciembre de 2011. En cada domingo se utilizaron las observaciones disponibles hasta ese momento para ajustar los modelos y generar pronósticos para los días abiertos de la semana siguiente.

Se obtuvieron 58 pronósticos diarios por modelo, y las métricas se calcularon agrupando los errores correspondientes a todas las fechas evaluadas.

Cuadro 27: Resultados de la evaluación temporal sobre el período de prueba

Modelo	MAE (£)	RMSE (£)
B1	23446.29	28178.58
B2	14655.25	18956.61
M1	15993.45	21191.19
M2	15727.48	20478.60
S1	17231.88	21644.59
S2	**12817.13**	**16216.65**

Como se observa en la Tabla 27, S2 obtuvo los menores errores durante el período de prueba, con un MAE de 12817.13 libras esterlinas y un RMSE de 16216.65 libras esterlinas. Este resultado contrasta con la validación temporal de entrenamiento, en la que M2 había presentado el mejor desempeño.

Al comparar los procedimientos de validación para B1, M1 y M2, se observó que los errores de la validación temporal de entrenamiento estuvieron más próximos a los obtenidos en prueba que los estimados mediante validación aleatoria. Sin embargo, ambos esquemas subestimaron los errores del período de prueba, lo que indica que las condiciones de este último período fueron más difíciles de pronosticar.

Estos resultados muestran que el procedimiento de validación influye en la estimación del desempeño y que obtener errores bajos durante el entrenamiento no garantiza mantener la misma precisión al evaluar observaciones posteriores.

Análisis del modelo con menor error en prueba

El modelo SARIMA S2 presentó los menores valores de MAE y RMSE durante la evaluación temporal de prueba. Por esta razón, se seleccionó para representar gráficamente la comparación entre las ventas reales y los pronósticos generados durante octubre y diciembre de 2011.

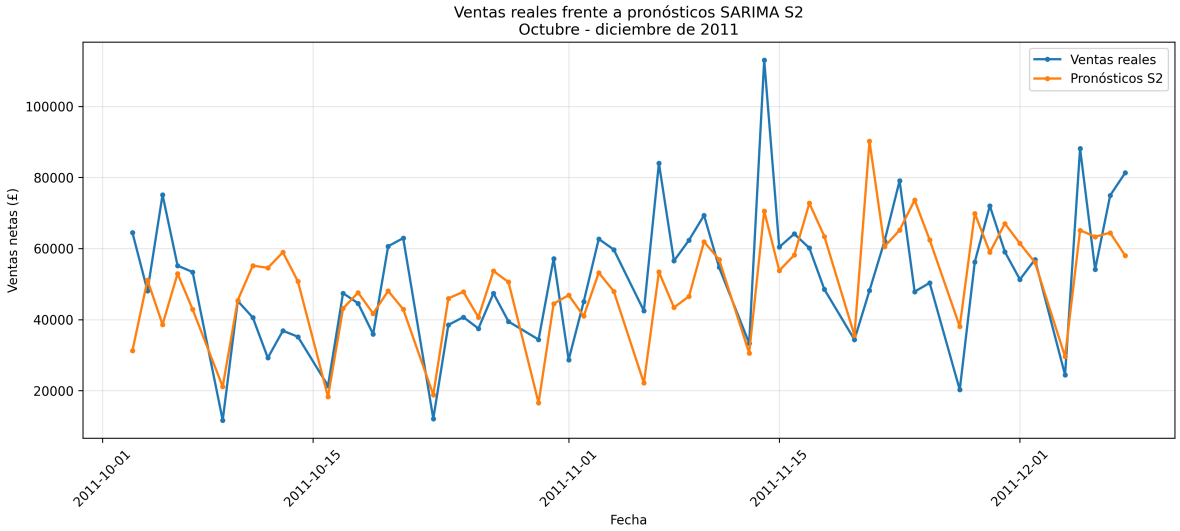


Figura 12: Comparación entre las ventas reales y los pronósticos del modelo SARIMA S2 durante el período de prueba.

En la Figura 12 se observa que S2 logra representar parte de las variaciones generales de las ventas, aunque presenta dificultades para anticipar algunos incrementos pronunciados y disminuciones abruptas. En determinadas fechas, las ventas reales superan considerablemente los valores pronosticados, lo que contribuye a los errores observados.

El comportamiento de S2 puede relacionarse con los diagnósticos de residuos realizados anteriormente. En la prueba de Ljung–Box, este modelo presentó valores p de 0.3418 y 0.4584 para los rezagos 6 y 12, respectivamente. Debido a que ambos valores fueron superiores al nivel de significancia de 0.05, no se rechazó la hipótesis nula de ausencia de autocorrelación residual en los rezagos evaluados.

Por el contrario, S1 presentó valores p de 0.0443 y 0.0093 para los mismos rezagos, lo que permitió rechazar la hipótesis nula al nivel de significancia de 0.05. Estos resultados indican que S1 conservó evidencia de dependencia temporal en sus residuos, mientras que S2 presentó un comportamiento residual más favorable según las pruebas aplicadas.

La diferencia entre los diagnósticos es coherente con el mejor desempeño de S2 durante la evaluación de prueba. No obstante, la ausencia de autocorrelación residual significativa no garantiza que los pronósticos sean precisos, ya que pueden existir cambios en el nivel de ventas o variaciones que el modelo no logre anticipar.

Es importante señalar que S2 se identificó como el modelo de menor error después de observar los resultados del período de prueba. Por lo tanto, esta selección describe el desempeño obtenido en la comparación realizada y no constituye una selección independiente efectuada antes de evaluar dicho período.

Experimento de fuga de información

Se realizó un experimento para demostrar cómo la incorporación de información futura en las variables predictoras puede producir resultados artificialmente favorables. Para ello, se modificó el modelo M2 mediante la incorporación de una media móvil centrada de siete días calendario, calculada sobre la serie completa antes de realizar las particiones de validación.

La media móvil centrada se definió como el promedio de las ventas observadas dentro de una ventana de siete días calendario, comprendida entre tres días anteriores y tres días posteriores a la fecha considerada. Los días cerrados, representados mediante valores faltantes, no participaron en el promedio.

$$MC_7(t) = \frac{\sum_{k=-3}^{3} I_{t+k} y_{t+k}}{\sum_{k=-3}^{3} I_{t+k}} \tag{7}$$

Donde I_{t+k} toma el valor de 1 cuando existe una venta observada en la fecha correspondiente y 0 cuando se trata de un día sin observación. De esta manera, el promedio se calcula únicamente con las ventas disponibles dentro de la ventana de siete días calendario.

El problema metodológico consiste en que esta variable incluye la venta del propio día que se desea pronosticar y puede incorporar ventas de fechas posteriores. En una situación real, dichos valores todavía no estarían disponibles al momento de emitir el pronóstico, por lo que su utilización constituye una fuga de información.

La versión modificada se denominó M2 con fuga y se evaluó mediante los mismos esquemas de validación utilizados anteriormente para el modelo original.

Validación cruzada aleatoria con fuga de información

Se repitió la validación cruzada aleatoria de cinco particiones y diez semillas, incorporando la media móvil centrada como una variable adicional del modelo M2. La característica se calculó previamente sobre la serie completa y posteriormente se utilizó en las particiones de entrenamiento y validación.

Cuadro 28: Comparación de M2 original y M2 con fuga en validación aleatoria

Modelo	MAE medio	Desv. MAE	RMSE medio	Desv. RMSE
M2 original	8567.25	180.20	11969.17	135.66
M2 con fuga	7461.04	128.33	10295.72	159.31

Los resultados de la Tabla 28 muestran que la incorporación de la media móvil centrada redujo el MAE aproximadamente un 12.9 % y el RMSE un 14.0 % respecto al modelo original. Aunque estas reducciones podrían interpretarse inicialmente como una mejora predictiva,

en realidad corresponden a una evaluación contaminada por información que no estaría disponible al momento del pronóstico.

Validación temporal con fuga de información

También se repitió la validación temporal con origen móvil semanal durante el período de entrenamiento. En este caso se conservaron los orígenes cronológicos y las mismas 129 fechas de evaluación, pero se utilizó la media móvil centrada calculada previamente sobre toda la serie.

Cuadro 29: Comparación de M2 original y M2 con fuga en validación temporal

Modelo	MAE (£)	RMSE (£)
M2 original	9397.75	13597.23
M2 con fuga	8478.85	11746.15

Como se observa en la Tabla 29, el MAE disminuyó aproximadamente un 9.8 % y el RMSE un 13.6 % al incorporar la variable contaminada. Este resultado demuestra que incluso un procedimiento de validación que respeta el orden cronológico puede producir métricas artificialmente favorables cuando las características utilizadas por el modelo fueron construidas con información futura.

Por lo tanto, evitar la fuga de información requiere controlar tanto la separación temporal de los datos como la construcción de las variables predictoras. Los resultados de M2 con fuga se presentan únicamente como una demostración metodológica y no representan una evaluación válida de su capacidad real para anticipar ventas.

No se consideró apropiado utilizar esta versión para seleccionar un modelo final a partir del período de prueba, debido a que sus pronósticos dependen de información que no estaría disponible en una aplicación real.

Comparación de errores entre entrenamiento y prueba

Se compararon los resultados obtenidos durante la validación temporal de entrenamiento con los correspondientes a la evaluación temporal del período de prueba. El objetivo fue analizar los cambios en el desempeño de los modelos e identificar posibles diferencias entre ambos períodos.

Para cada modelo se calculó la variación porcentual del MAE y del RMSE mediante la ecuación 8.

$$\Delta_{\%} = \frac{E_{\text{prueba}} - E_{\text{entrenamiento}}}{E_{\text{entrenamiento}}} \times 100 \tag{8}$$

Donde $E_{\text{entrenamiento}}$ representa el error obtenido durante la validación temporal de entrenamiento y E_{prueba} corresponde al error observado durante la evaluación temporal de prueba.

Cuadro 30: Variación porcentual de los errores entre entrenamiento y prueba

Modelo	Cambio MAE (%)	Cambio RMSE (%)
B1	121.69	84.26
B2	26.47	19.26
M1	59.23	49.14
M2	67.35	50.61
S1	73.49	53.61
S2	23.42	12.73

La Tabla 30 muestra que todos los modelos presentaron incrementos en ambas métricas durante el período de prueba. El modelo B1 registró el mayor aumento relativo, con un incremento del MAE de 121.69 %, mientras que S2 presentó el menor incremento, con 23.42 % en MAE y 12.73 % en RMSE.

La Figura 13 permite visualizar las diferencias del MAE entre ambos períodos para los seis modelos evaluados.

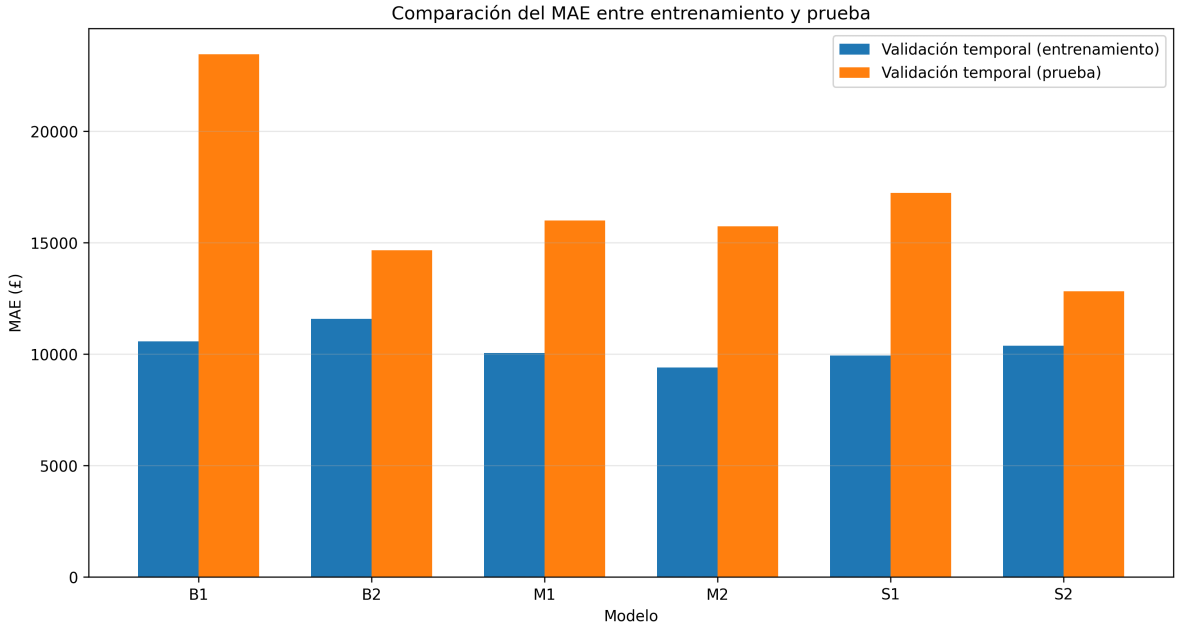


Figura 13: Comparación del MAE de los seis modelos entre la validación temporal de entrenamiento y el período de prueba.

Como se observa en la Figura 13, todos los modelos presentaron errores mayores durante el período de prueba. El incremento fue especialmente pronunciado para B1, lo que es compatible con las limitaciones de utilizar un promedio histórico cuando el comportamiento de las ventas cambia con el tiempo.

Aunque M2 había obtenido el menor error durante la validación temporal de entrenamiento, S2 presentó el mejor desempeño durante el período de prueba. Esto indica que el orden relativo de los modelos cambió entre los períodos evaluados y que el desempeño obtenido durante el entrenamiento no necesariamente se mantiene en observaciones posteriores.

Una posible explicación es que el comportamiento de las ventas durante octubre y diciembre haya presentado diferencias respecto a los meses anteriores, tanto en su nivel como en su variabilidad. Sin embargo, los resultados disponibles no permiten atribuir el incremento de los errores exclusivamente a un cambio de distribución, ya que también pueden influir la composición de las observaciones y las características de cada modelo.

Por otra parte, la comparación con la validación aleatoria mostró que el esquema de evaluación puede producir estimaciones optimistas del error. Para B1, M1 y M2, la validación temporal de entrenamiento proporcionó resultados más cercanos a los observados en prueba, lo que respalda la importancia de utilizar procedimientos que respeten el orden cronológico al evaluar modelos de series de tiempo.

Finalmente, debe considerarse que la serie analizada comprende aproximadamente un año de información. Aunque esta extensión permite estudiar patrones semanales, no proporciona suficientes ciclos anuales completos para estimar y comprobar con confianza una estacionalidad anual recurrente. Por ello, cualquier posible comportamiento asociado con temporadas comerciales específicas debe interpretarse con precaución y requeriría información de varios años para su confirmación.

Conclusiones de la evaluación de pronósticos

La comparación de los seis modelos permitió identificar diferencias importantes entre los procedimientos de validación y los períodos evaluados. M2 obtuvo los menores errores durante la validación temporal de entrenamiento, mientras que S2 presentó el mejor desempeño durante la evaluación temporal de prueba, con un MAE de 12817.13 libras esterlinas y un RMSE de 16216.65 libras esterlinas.

Los resultados mostraron que la validación temporal fue más representativa que la validación aleatoria para aproximar los errores de prueba de B1, M1 y M2, aunque ambos procedimientos subestimaron los errores observados posteriormente. Asimismo, el experimento de fuga de información evidenció que utilizar variables calculadas con datos futuros puede reducir artificialmente las métricas, incluso cuando se conserva el orden cronológico de la validación.

El incremento generalizado de los errores durante el período de prueba resalta la importancia de evaluar los modelos sobre observaciones posteriores al entrenamiento y de considerar posibles cambios temporales en el comportamiento de las ventas. Finalmente, la disponibilidad de aproximadamente un año de datos constituye una limitación para el análisis de patrones anuales, por lo que las conclusiones sobre estacionalidad deben restringirse a los comportamientos que pueden estudiarse con la información disponible.

5. Parte 6: Análisis RFM y comportamiento de clientes

Cálculo de RFM

Para realizar el análisis RFM se utilizaron las transacciones limpias con identificador de cliente, considerando únicamente la información anterior al 1 de octubre de 2011. Se calcularon tres variables por cliente: recencia (R), frecuencia (F) y monto monetario (M).

La recencia se definió como el número de días transcurridos entre la última compra y la fecha de corte. La frecuencia corresponde al número de facturas de venta distintas realizadas por el cliente, mientras que el monto monetario representa la suma neta de sus transacciones, incluyendo las cancelaciones registradas.

$$R_i = \text{Fecha de corte} - \text{Fecha de última compra}_i \tag{9}$$

$$F_i = \text{Número de facturas de venta distintas del cliente } i \tag{10}$$

$$M_i = \sum_{j \in T_i} Q_j P_j \tag{11}$$

Donde T_i representa las transacciones del cliente i, Q_j la cantidad de productos y P_j el precio unitario de cada transacción.

Se identificaron 3,615 clientes con al menos una compra anterior a la fecha de corte. La Tabla 31 presenta las principales estadísticas descriptivas de las variables RFM.

Cuadro 31: Estadísticas descriptivas de las variables RFM

Estadístico	**Recencia**	**Frecuencia**	**Monto**
Media	92.90	3.64	1618.04
Desviación estándar	86.81	6.12	6636.66
Mínimo	1.00	1.00	-1161.55
Primer cuartil	19.00	1.00	269.11
Mediana	64.00	2.00	582.47
Tercer cuartil	149.00	4.00	1407.32
Máximo	304.00	139.00	202389.64

Se encontraron 13 clientes con monto monetario menor o igual a cero. Estos valores pueden producirse cuando las cancelaciones compensan o superan las compras registradas. Se decidió conservarlos en el análisis, ya que representan resultados netos válidos y excluirlos modificaría la población de clientes utilizada para construir los quintiles.

Finalmente, se evitó utilizar información posterior al 1 de octubre de 2011 en el cálculo de RFM, porque el objetivo es evaluar si el comportamiento histórico permite anticipar las compras del período siguiente. Incorporar transacciones futuras produciría una fuga de información y afectaría la validez de la evaluación.

Asignación de quintiles RFM

A partir de los 3,615 clientes identificados en el ejercicio anterior, se asignaron puntuaciones de 1 a 5 para las variables de recencia (R), frecuencia (F) y monto monetario (M), utilizando quintiles. Cada puntuación representa aproximadamente el 20 % de los clientes, donde 1 corresponde al nivel más bajo y 5 al más alto.

Para la recencia, se invirtió el orden de clasificación, debido a que un menor número de días desde la última compra representa un mejor comportamiento de compra. Por lo tanto, los clientes que compraron más recientemente reciben una puntuación de 5. En frecuencia y monto monetario, los valores más altos reciben las puntuaciones más altas.

Debido a que varios clientes presentan la misma frecuencia de compra, fue necesario establecer un procedimiento para resolver los empates. Primero se ordenaron todos los clientes por su identificador (`CustomerID`), incluyendo aquellos cuyo monto monetario era menor o igual a cero. Posteriormente, se aplicó una permutación aleatoria reproducible mediante `numpy.random.default_rng(2026).permutation`. Finalmente, se asignaron los quintiles de frecuencia utilizando `pd.qcut(F.rank(method='first'), 5)`.

Este procedimiento permite distribuir a los clientes con frecuencias iguales entre diferentes quintiles, sin alterar sus valores originales de frecuencia. La semilla 2026 garantiza que el desempate pueda reproducirse al ejecutar nuevamente el programa.

Cuadro 32: Distribución de clientes por quintiles RFM

Puntuación	**Recencia**	**Frecuencia**	**Monto**
1	723	723	723
2	723	723	723
3	723	723	723
4	723	723	723
5	723	723	723
Total	**3,615**	**3,615**	**3,615**

Como se observa en la Tabla 32, cada dimensión presenta una distribución uniforme de 723 clientes por quintil. Esto se debe a que se utilizó el rango de los valores para realizar la división en cinco grupos del mismo tamaño.

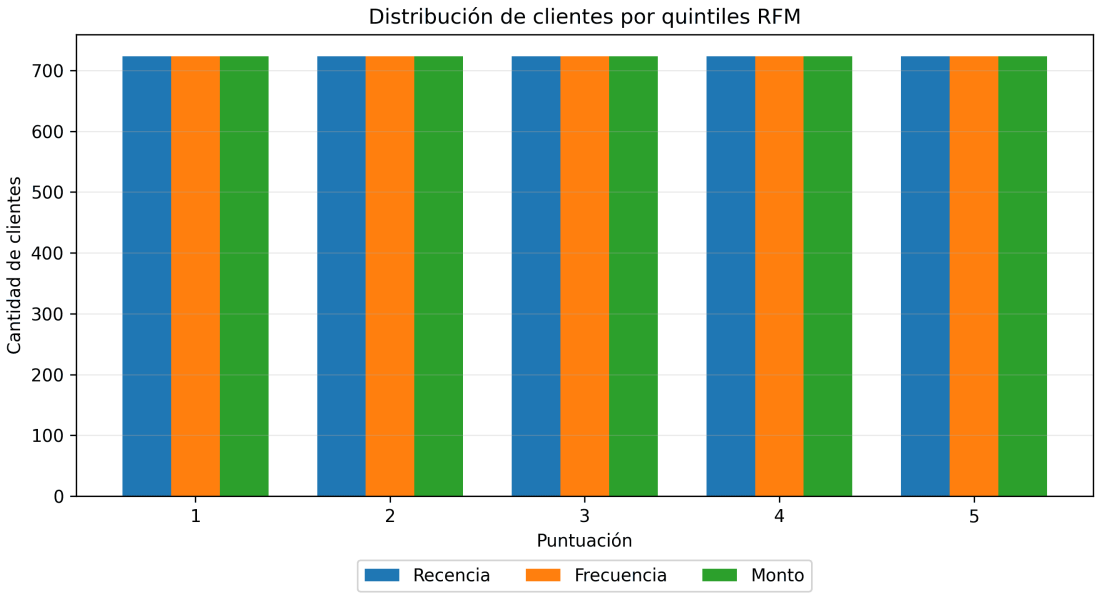


Figura 14: Distribución de clientes por puntuación de recencia, frecuencia y monto monetario.

La Figura 14 confirma que los clientes fueron distribuidos de manera equilibrada entre los cinco quintiles de cada variable. Esta distribución corresponde al procedimiento de clasificación utilizado y no implica que los clientes tengan comportamientos de compra similares.

En particular, se identificaron 1,444 clientes con una sola factura de venta. De ellos, 723 recibieron una puntuación de frecuencia igual a 1 y 721 una puntuación igual a 2. Esto demuestra que dos clientes con la misma frecuencia pueden recibir puntuaciones distintas cuando existe un empate que debe resolverse para mantener el tamaño de los quintiles.

Finalmente, se calculó un puntaje RFM combinado mediante la suma de las tres puntuaciones:

$$S_i = R_{\text{score},i} + F_{\text{score},i} + M_{\text{score},i} \tag{12}$$

El puntaje combinado puede tomar valores entre 3 y 15 y será utilizado en el siguiente ejercicio para evaluar su capacidad de discriminar entre clientes que vuelven a comprar y aquellos que no realizan nuevas compras.

Evaluación de recompra

Para evaluar la capacidad de las variables RFM de identificar clientes que vuelven a comprar, se utilizó como período de evaluación el comprendido entre el 1 de octubre y el 8 de diciembre de 2011, inclusive. Se consideraron los 3,615 clientes identificados antes de la fecha de corte, sin modificar sus puntuaciones RFM con información del período de evaluación.

Se definió una variable binaria de recompra para cada cliente:

$$\text{compra}_i = \begin{cases} 1, & \text{si el cliente } i \text{ realizó al menos una compra en el período,} \\ 0, & \text{en caso contrario.} \end{cases} \tag{13}$$

Para identificar una compra se consideraron las facturas de venta con cantidades positivas, excluyendo las cancelaciones. De los 3,615 clientes evaluados, 1,835 realizaron al menos una nueva compra, lo que representa una tasa de recompra del 50.76 %.

Tasas de recompra por quintil

Se calculó la fracción de clientes que volvieron a comprar para cada puntuación de recencia, frecuencia y monto monetario. Los resultados se presentan en la Tabla 33.

Cuadro 33: Tasas de recompra según los quintiles RFM

Puntuación	**Recencia (%)**	**Frecuencia (%)**	**Monto (%)**
1	28.08	33.06	29.32
2	38.04	31.12	37.90
3	55.33	44.81	45.64
4	66.25	59.06	60.44
5	66.11	85.75	80.50

Los resultados muestran que las tasas de recompra tienden a aumentar conforme mejoran las puntuaciones RFM. En recencia, los clientes del quintil 1 presentan una tasa de recompra del 28.08 %, mientras que los del quintil 5 alcanzan el 66.11 %. Sin embargo, los quintiles 4 y 5 presentan valores muy similares, por lo que la relación no es estrictamente creciente.

En frecuencia se observa una diferencia más pronunciada. Los clientes del quintil 5 presentan una tasa de recompra del 85.75 %, considerablemente superior a la del quintil 1, que alcanza el 33.06 %. La ligera disminución entre los quintiles 1 y 2 puede relacionarse con el procedimiento de desempate, ya que ambos grupos incluyen clientes con una sola factura histórica.

El monto monetario también presenta una relación positiva con la recompra. La tasa aumenta desde el 29.32 % en el quintil 1 hasta el 80.50 % en el quintil 5, lo que sugiere que los clientes con mayores montos históricos tienden a realizar nuevas compras con mayor frecuencia.

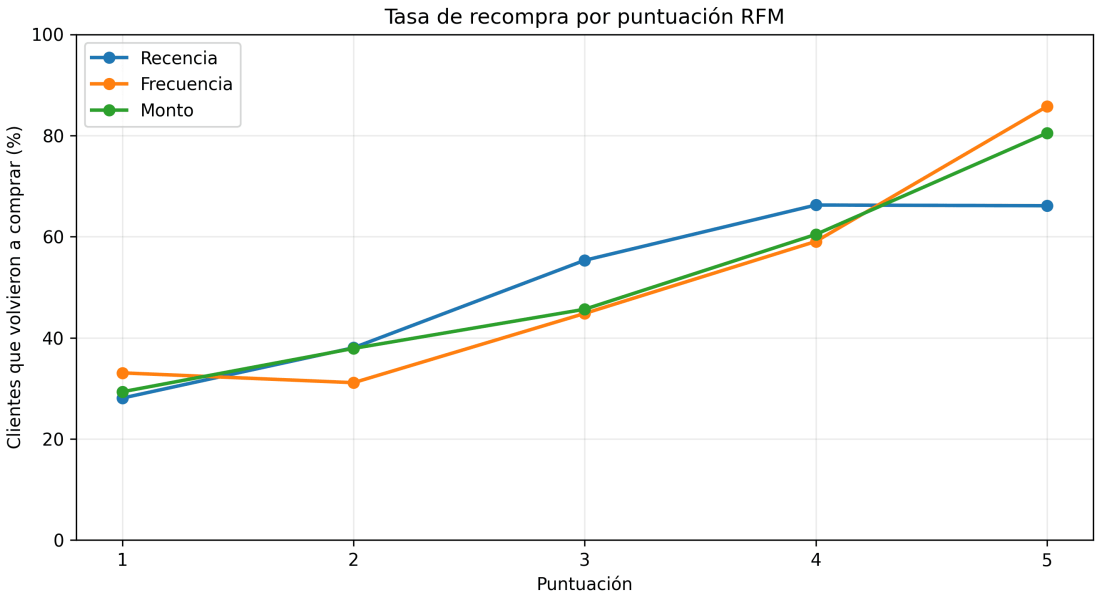


Figura 15: Tasas de recompra por puntuación de recencia, frecuencia y monto monetario.

La Figura 15 permite comparar visualmente el comportamiento de las tres dimensiones. Se observa que frecuencia y monto presentan un incremento especialmente marcado en el quintil 5, mientras que recencia muestra una estabilización de la tasa de recompra en los dos quintiles superiores.

Comparación de clasificadores mediante AUC

Para comparar la capacidad de discriminación de las variables RFM se utilizó el área bajo la curva ROC (AUC). Esta métrica permite evaluar qué tan bien una puntuación distingue entre clientes que realizaron una nueva compra y aquellos que no compraron durante el período de evaluación.

Se calcularon los AUC utilizando los valores originales de recencia, frecuencia y monto monetario, además de la suma de las puntuaciones RFM. Para recencia se utilizó su valor negativo, debido a que un menor número de días desde la última compra indica una mayor probabilidad esperada de recompra.

Cuadro 34: Comparación de AUC para los clasificadores RFM

Clasificador	**AUC**
Recencia	0.6719
Frecuencia	0.7198
Monto monetario	0.7078
Puntaje RFM combinado	**0.7325**

Como se observa en la Tabla 34, la frecuencia presenta el mayor AUC entre las variables individuales, con un valor de 0.7198. Le siguen el monto monetario, con 0.7078, y la recencia, con 0.6719.

El puntaje RFM combinado obtiene el mejor resultado, con un AUC de 0.7325. Esto indica que la combinación de las tres dimensiones proporciona una mayor capacidad de discriminación de la recompra que cada variable considerada individualmente.

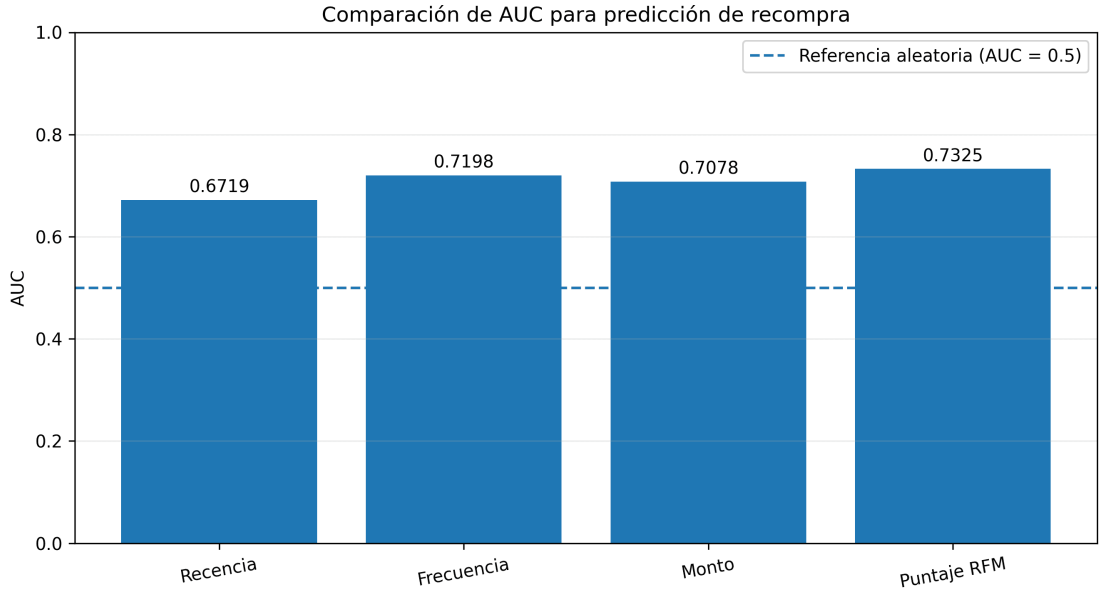


Figura 16: Comparación del AUC de recencia, frecuencia, monto y puntaje RFM combinado.

La Figura 16 muestra que todos los clasificadores superan el valor de referencia de 0.5, correspondiente a una discriminación equivalente al azar. No obstante, ninguno alcanza un AUC cercano a 1, por lo que todavía existe incertidumbre al distinguir entre clientes que volverán a comprar y aquellos que no lo harán.

En conjunto, los resultados muestran que el comportamiento histórico de los clientes contiene información útil para identificar tendencias de recompra. Sin embargo, el análisis RFM constituye una herramienta de clasificación y segmentación, y sus resultados no deben interpretarse como predicciones exactas de las compras futuras.

Identificación de clientes Champions

A partir de las puntuaciones RFM calculadas con información anterior al 1 de octubre de 2011, se identificaron los clientes denominados *Champions*. Para pertenecer a este segmento, un cliente debía obtener una puntuación de 4 o 5 simultáneamente en recencia, frecuencia y monto monetario.

La condición utilizada para clasificar a un cliente como Champion fue:

$$\text{Champion}_i = \begin{cases} 1, & \text{si } R_{\text{score},i} \geq 4,\ F_{\text{score},i} \geq 4,\ M_{\text{score},i} \geq 4, \\ 0, & \text{en caso contrario.} \end{cases} \tag{14}$$

De los 3,615 clientes analizados, 775 cumplieron con esta condición. La proporción de clientes Champions se calculó mediante:

$$P_{\text{Champions}} = \frac{775}{3615} \times 100 = 21{,}44\,\% \tag{15}$$

Posteriormente, se calculó la contribución de estos clientes a las ventas netas realizadas entre el 1 de octubre y el 8 de diciembre de 2011. Para este cálculo se consideraron las transacciones de todos los clientes identificados durante el período, incluyendo clientes antiguos y nuevos. Asimismo, se incluyeron las cancelaciones para obtener el importe neto de las ventas.

Los resultados se presentan en la Tabla 35.

Cuadro 35: Resultados de la identificación de clientes Champions

Indicador	**Resultado**
Clientes históricos analizados	3,615
Clientes Champions	775
Porcentaje de clientes Champions	21.44 %
Ventas netas totales del período	2,432,839.69
Ventas netas de clientes Champions	1,295,784.14
Participación de Champions en las ventas	53.26 %

La participación de los clientes Champions en las ventas netas se calculó mediante:

$$P_{\text{ventas Champions}} = \frac{1,295,784{,}14}{2,432,839{,}69} \times 100 = 53{,}26\,\% \tag{16}$$

Los resultados muestran que, aunque los clientes Champions representan únicamente el 21.44 % de la población histórica, generaron el 53.26 % de las ventas netas del período de evaluación. Esto evidencia una concentración importante de las ventas en un grupo relativamente reducido de clientes con un comportamiento histórico favorable.

La diferencia entre la proporción de clientes y su participación en las ventas sugiere que las variables RFM permiten identificar segmentos de alto valor comercial. En particular, los clientes con compras recientes, frecuentes y de mayor monto histórico contribuyeron de manera considerable a los ingresos posteriores.

Es importante señalar que la clasificación de Champions se realizó utilizando únicamente información disponible antes de la fecha de corte. Por lo tanto, su participación en las ventas del período de evaluación representa un resultado posterior y no una característica utilizada para construir la segmentación.

Participación de clientes nuevos en las ventas

Para determinar la contribución de los clientes nuevos a las ventas netas, se utilizó el período comprendido entre el 1 de octubre y el 8 de diciembre de 2011, inclusive. Se consideró como cliente nuevo a aquel que realizó al menos una compra durante este período y que no tenía ninguna factura de venta registrada antes del 1 de octubre de 2011.

La identificación se realizó comparando los clientes que efectuaron compras durante el período de evaluación con aquellos que tenían compras anteriores a la fecha de corte. Para calcular las ventas netas se incluyeron tanto las transacciones de venta como las cancelaciones, considerando únicamente las operaciones con identificador de cliente.

Se identificaron 721 clientes nuevos, cuyas ventas netas ascendieron a 382,365.98. Las ventas netas totales del período fueron de 2,432,839.69.

La participación de los clientes nuevos se calculó mediante:

$$P_{\text{clientes nuevos}} = \frac{\text{Ventas netas de clientes nuevos}}{\text{Ventas netas totales}} \times 100 \tag{17}$$

Sustituyendo los valores obtenidos:

$$P_{\text{clientes nuevos}} = \frac{382,365{,}98}{2,432,839{,}69} \times 100 = 15{,}72\,\% \tag{18}$$

Los resultados se presentan en la Tabla 36.

Cuadro 36: Participación de los clientes nuevos en las ventas netas

Indicador	**Resultado**
Clientes nuevos identificados	721
Ventas netas totales	2,432,839.69
Ventas netas de clientes nuevos	382,365.98
Participación de clientes nuevos	15.72 %

Los resultados indican que el 15.72 % de las ventas netas del período de evaluación provino de clientes que no tenían compras registradas antes de la fecha de corte. Esto representa una contribución importante que no puede explicarse únicamente mediante el comportamiento histórico de los clientes existentes.

Distribución de las ventas por segmento de clientes

Para complementar el análisis, se comparó la participación de los clientes Champions, los clientes nuevos y los demás clientes identificados durante el período de evaluación.

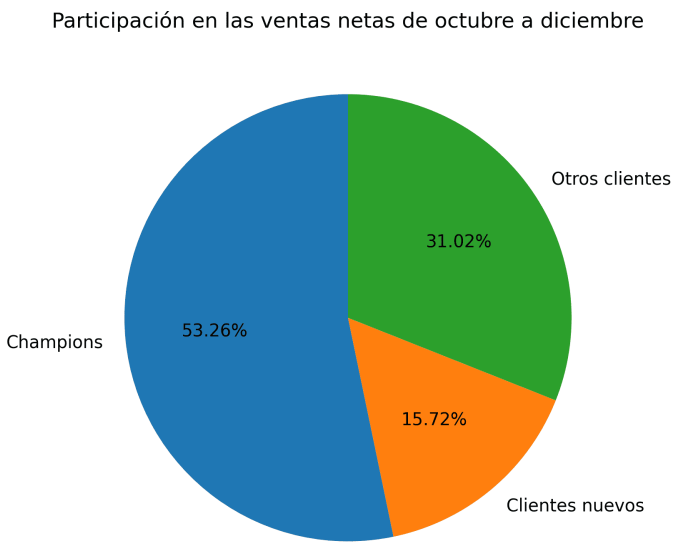


Figura 17: Distribución de las ventas netas entre clientes Champions, clientes nuevos y otros clientes durante el período de evaluación.

Como se observa en la Figura 17, los clientes Champions concentraron el 53.26 % de las ventas netas, mientras que los clientes nuevos aportaron el 15.72 %. El 31.02 % restante correspondió a otros clientes identificados.

Esta distribución evidencia que las ventas provienen tanto de clientes con un historial favorable como de clientes que se incorporan durante el período de evaluación. Por lo tanto, para estimar las ventas totales resulta importante considerar ambos componentes.

Limitaciones del análisis RFM y relación con los enfoques de pronóstico

El análisis RFM permite describir y clasificar el comportamiento de los clientes que cuentan con un historial de compras. Sin embargo, no puede pronosticar directamente el comportamiento individual de clientes nuevos, debido a que estos no disponen de información histórica para calcular recencia, frecuencia y monto monetario antes de su primera compra.

Esta limitación se relaciona con los enfoques de pronóstico *top-down* y *bottom-up*.

En la Parte 5 se utilizó un enfoque agregado, o *top-down*, para pronosticar las ventas a partir de una serie temporal. Este enfoque considera el comportamiento global de las ventas y puede incorporar indirectamente la contribución histórica de clientes nuevos y existentes, aunque no permite identificar individualmente quién realizará las compras.

Por otra parte, un enfoque *bottom-up* busca construir una estimación global a partir del comportamiento de unidades individuales, como los clientes. En este contexto, las variables RFM pueden utilizarse para estimar la probabilidad de recompra de clientes conocidos. Sin embargo, si solamente se consideran estos clientes, se omite la contribución de quienes todavía no han realizado su primera compra.

Una alternativa consiste en combinar ambos enfoques, estimando por separado las ventas esperadas de clientes existentes y la contribución de nuevos clientes:

$$\widehat{V}_{\text{total}} = \widehat{V}_{\text{existentes}} + \widehat{V}_{\text{nuevos}} \tag{19}$$

Donde $\widehat{V}_{\text{existentes}}$ representa las ventas pronosticadas de clientes conocidos y $\widehat{V}_{\text{nuevos}}$ corresponde a una estimación de las ventas generadas por clientes que se incorporarán posteriormente.

Esta distinción también es relevante para el Proyecto 1, ya que una simulación o modelo de ventas basado únicamente en clientes existentes podría subestimar los resultados al no representar la llegada de nuevos compradores. Por ello, sería necesario incorporar un mecanismo adicional para estimar la adquisición de clientes y su contribución a las ventas.

En conclusión, el análisis RFM proporciona información útil para identificar clientes con mayor tendencia a recomprar y segmentos de alto valor comercial, pero no sustituye por sí solo un modelo de pronóstico de ventas totales. Su combinación con métodos de series temporales o modelos de adquisición de clientes permitiría representar de manera más completa el comportamiento comercial.